

Introducción a la inteligencia artificial

Nombre: Roberto Alvarado

Fecha: 04 de Mayo del 2025

1. Introducción

Para este trabajo, tomaré los siguientes tres temas,

1. Planteamiento del problema.
2. Contenidos del marco teórico.
3. Selección de la metodología.

cada una de las secciones serán los pasos del trabajo y los números de los temas son los mismos para todo el documento

2. Prompt para cada tema

Después de leer varios documentos sobre cuales serían los mejores prompts para este proceso, (Bardo, 2025),(Okorie, 2025), (ahmetbersoz, s.f.) los prompts que decidí utilizar para cada tema son los siguientes. Puede notarse que se parecen mucho, ya que siempre busco darle un contexto al modelo para entender que es lo que busca hacer, entonces mis prompts estan estructurados de la siguiente manera

- Un parte del prompt que le de contexto de como espero que el modelo se comporte, aqui como un analista de datos, con experiencia en medicina y en investigación académica
- Una parte que explique la situación actual de la investigación. Por ejemplo, tengo una base de datos, etc
- Una parte que explique los objetivos del proyecto
- Una parte que pida lo que necesito para cada tema, esto variará para cada tema
- Y finalmente una parte que explique la forma que quiero el resultado, por ejemplo, que me de citas, que me de el formato de la cita y que utilice el internet

Estos son los prompts que utilicé con cada modelo

1. Eres un analista de datos que tiene experiencia en análisis de datos y en investigaciones académicas. Tienes un fuerte background de medicina. Tienes una base de datos sobre la enfermedad renal crónica, estos datos tienen un número de atributos y una clasificación. Según estos datos, quieres hacer una investigación para una tesis de maestría, que tiene dos fines, uno utilizar un modelo para predecir la enfermedad, y otro hacer una herramienta para que los doctores lo utilicen de manera que ellos puedan predecir enfermedad renal crónica. Tu objetivo ahora es hacer un planteamiento del problema que irá en el documento final. asegúrate que solo sea el planteamiento del problema para la tesis. Por favor, quiero que hagas uso del internet, y me ayudes citando cualquier dato que necesites, necesito que estén citadas en apa. Dame también después de que termines las citas en bibtex.

El resultado de **ChatGPT** se encuentra en Anexo 1.

El resultado de **Gemini** se encuentra en Anexo 2.

El resultado de **Claude** se encuentra en Anexo 3.

2. Eres un analista de datos que tiene experiencia en análisis de datos y en investigaciones académicas. Tienes un fuerte background de medicina. Tienes una base de datos sobre la enfermedad renal crónica, estos datos tienen un número de atributos y una clasificación. Según estos datos, quieres hacer una investigación para una tesis de maestría, que tiene dos fines, uno utilizar un modelo para predecir la enfermedad, y otro hacer una herramienta para que los doctores lo utilicen de manera que ellos puedan predecir enfermedad renal crónica. Tu

objetivo ahora es hacer un marco teórico que irá en el documento final. Quiero que para cada tema, hagas una explicación exhaustiva al nivel de un estudiante de posgrado y las citas al estilo apa asegúrate que solo sea el objetivo que te planteo. Por favor, quiero que hagas uso del internet, y me ayudes citando cualquier dato que necesites, necesito que estén citadas en apa. Dame también después de que termines las citas en bibtex. Asegurate que las citas en bibtex solo esten al final

El resultado de **ChatGPT** se encuentra en Anexo 4.

El resultado de **Gemini** se encuentra en Anexo 5.

El resultado de **Claude** se encuentra en Anexo 6.

3. Eres un analista de datos que tiene experiencia en análisis de datos y en investigaciones académicas. Tienes un fuerte background de medicina. Tienes una base de datos sobre la enfermedad renal crónica, estos datos tienen un número de atributos y una clasificación. Según estos datos, quieres hacer una investigación para una tesis de maestría, que tiene dos fines, uno utilizar un modelo para predecir la enfermedad, y otro hacer una herramienta para que los doctores lo utilicen de manera que ellos puedan predecir enfermedad renal crónica. Tu objetivo es plantear una selección de la metodología, intenta plantearla de forma que sea lo que se va a presentar en el documento final Asegúrate que solo sea el objetivo que te planteo. Por favor, quiero que hagas uso del internet, y me ayudes citando cualquier dato que necesites, necesito que estén citadas en apa. Dame también después de que termines las citas en bibtex. Asegurate que las citas en bibtex solo esten al final

El resultado de **ChatGPT** se encuentra en Anexo 7.

El resultado de **Gemini** se encuentra en Anexo 8.

El resultado de **Claude** se encuentra en Anexo 9.

3. Análisis de los resultados

Comprobar la veracidad de los resultados, es complicado debido a mi falta de contexto de todos los temas que se hablan en las respuestas, la mejor manera que pude hacerlo es comprobar que las referencias (en los anexos) sean verdaderas, además de leerlo y ver si puedo entenderlo. Para cada sección haré un pequeño análisis y las cosas que más me llamaron la atención

■ Tema 1. Planteamiento del problema

- **ChatGPT** En general fue una respuesta buena, sencilla y manejable de entender, todas las referencias tenían hiperlinks que me llevaban a páginas existentes. Tiene un prejuicio grande con fuentes en español, me imagino que es debido a que hice la pregunta en ese idioma. Tiene un lenguaje formal y manejable
- **Gemini** Hizo un análisis mas exhaustivo de lo que hizo ChatGPT, parece tener igualmente el prejuicio del español, pero tiene artículos citados que originalmente estaban en inglés. Es una explicación mucho más grande de la problemática. Los links que utilizó me llevaron a páginas que funcionaban. Ahora, no pude acceder a los artículos ya que estaban con una barrera de pago
- **Claude** El análisis a comparación de los otros hizo un análisis mucho más contundente con referencias de varios lugares. En este todas las referencias venían de fuentes variadas sin preferencia al español. Hizo un análisis de las limitantes que es lo más destacable en comparación a las otras herramientas.

■ Tema 2. Contenidos del marco teórico

- **ChatGPT** Hizo un muy buen trabajo en estructurar el marco teórico, fue lo suficientemente preciso para encontrar lo que la literatura actual dice de la predicción. Otra vez la preferencia de referencias en español.
- **Gemini** Considero que hizo un perfecto balance entre medicina y análisis de datos, tuvo citas, no solo en español, de las que pude acceder sin problemas. Tuvo la mejor estructura entre todos, ya que a veces, lo conciso es mejor que lo extenso.
- **Claude** Fue sorprendente, al momento de utilizar el prompt, Claude presento un marco teórico completo, casi "presentable como un documento de investigación, fue muy largo, pero cada uno de sus datos tenían una cita. Algo interesante es que algunas de las citas

no las pude encontrar, sin embargo, cuando las busque por el autor, pude encontrarlas con un nombre diferente. La distribución de temas, me pareció la más completa, tanto así que consideraré para estructurar mi trabajo. Siento que se centro mucho en la parte médica, y no mucho en los modelos, pero eso puede ser por lo que llegó a su límite de tokens

■ Tema 3. Selección de metodología

- **ChatGPT** Aquí ChatGPT me decepcionó, fue muy parcial con las fuentes que encontró, me encuentro en Chile, y casi todas sus fuentes estaban centradas en eso, tanto así, que su escritura se basa como si la investigación estuviera solo en Chile. Además no le importó lo suficiente el tema de la creación de la herramienta para médicos
- **Gemini** Fue interesante, concisa, todos sus temas tenían sentido y siento que lo tomaré muy en cuenta para cuando decida la metodología. Sus citas funcionaron y no parecían tener ningún tipo de preferencias. Además hizo algo interesante, que fue agregar un paso a la metodología que era las consideraciones éticas
- **Claude** Claude hizo un trabajo muy interesante ya que para cada parte del proceso, hizo una lista de pasos que se deben seguir, siento que fue más como una lista de cosas por hacer, cosa que no me molesta pero me sorprendió. Este también consideró la interpretación de los datos. Algo muy interesante es que consideró algo nuevo, que junto a mi tutora sabíamos que sería difícil, pero Claude lo anticipo sin ninguna idea, la selección de características.

4. Resultados

Estos son los resultados con mis arreglos

4.1. Planteamiento del problema

La enfermedad renal crónica (ERC) se ha consolidado como un desafío global de salud pública, con una prevalencia que supera el 9 % a nivel mundial y una incidencia en constante aumento, generando una carga significativa en términos de morbilidad, mortalidad y costos económicos para los sistemas de salud (Pillajo Sánchez, Guacho Guacho, y Moya Guerrero, 2021) . Su naturaleza insidiosa, a menudo asintomática en las fases iniciales, dificulta el diagnóstico precoz, lo que retrasa la implementación de intervenciones terapéuticas oportunas y efectivas que podrían ralentizar su progresión y prevenir complicaciones graves (SysmexEspaña, s.f.).

La necesidad de herramientas predictivas que permitan identificar a individuos con alto riesgo de desarrollar ERC en etapas preclínicas es vital en la actualidad. Tales herramientas permitirán a los profesionales de la salud, especialmente en la atención primaria, implementar estrategias de prevención, modificación de factores de riesgo y un seguimiento más proactivo, lo que potencialmente mejoraría los resultados a largo plazo para los pacientes y reduciría la carga de la enfermedad (Ministerio de Salud de Chile, 2010).

A pesar de los avances en la comprensión de los factores de riesgo y la fisiopatología de la ERC, la integración de esta información en un formato predictivo accesible y utilizable por los médicos en su práctica diaria sigue siendo un reto (Gallardo Vidal, 2016). La complejidad de los datos clínicos y los múltiples factores que contribuyen al desarrollo de la ERC dificultan la toma de decisiones informadas y personalizadas por parte de los profesionales. En este contexto, la aplicación de técnicas avanzadas de análisis de datos y aprendizaje automático emerge como una solución prometedora para desarrollar modelos predictivos robustos que puedan discernir patrones sutiles en grandes conjuntos de datos, lo que a su vez podría traducirse en una mejor capacidad para identificar el riesgo de ERC antes de su manifestación clínica evidente (Gonzalez, 2022).

Sin embargo, tener un modelo que prediga la enfermedad, por muy preciso que sea, no significa automáticamente que los médicos lo usarán en su día a día. Es clave que este modelo se convierta en una herramienta que ayude a los doctores a tomar decisiones (conocida como TADC). Esta herramienta debe ser sencilla de entender y de usar, además de encajar fácilmente en la rutina de trabajo de los profesionales de la salud (AETSA, s.f.). Cuando faltan estas herramientas, los médicos tienen dificultades para procesar la enorme cantidad de información de los pacientes y para aplicar los últimos avances sobre la ERC. Esto puede llevar a diagnósticos tardíos, tratamientos que no son los más adecuados y a manejar la enfermedad solo cuando ya está avanzada, en lugar de prevenirla.

Considerando la disponibilidad de una base de datos con atributos clínicos y de clasificación sobre la ERC, este proyecto de tesis se propone abordar la siguiente problemática: ¿Cuál es la mejor manera de desarrollar y validar un modelo predictivo de enfermedad renal crónica utilizando datos existentes, y cómo se puede transformar este modelo en una herramienta de apoyo a la decisión clínica efectiva y utilizable por los profesionales de la salud para mejorar la predicción temprana y la gestión proactiva de la ERC?

4.2. Contenidos del marco teórico

La presente investigación se enmarca dentro de un diseño de estudio observacional, retrospectivo y analítico, con un enfoque mixto que combina la ciencia de datos (análisis predictivo mediante aprendizaje automático) y la ingeniería de software (desarrollo de una herramienta de apoyo a la decisión clínica). El estudio tiene como finalidad el desarrollo y validación de un modelo predictivo para la enfermedad renal crónica (ERC) y la posterior implementación de una herramienta informática para su uso por profesionales de la salud.

4.2.1. Fuente y Recolección de Datos

La base de datos utilizada para esta investigación proviene de una fuente previamente recopilada y anonimizada, conteniendo un número de atributos clínicos y demográficos relevantes para la predicción de la ERC, así como una clasificación dicotómica que indica la presencia o ausencia de la enfermedad. Se asegurará que la base de datos cumple con todas las normativas de privacidad y protección de datos personales (RGPD, HIPAA, según corresponda a la fuente original), garantizando la confidencialidad de la información de los pacientes.

Antes del análisis, se realizará un proceso exhaustivo de preprocesamiento de datos, que incluirá:

- Limpieza de Datos: Identificación y tratamiento de valores atípicos (outliers) y datos faltantes (missing values). Se evaluarán métodos como la imputación de valores por la media, mediana, moda o técnicas más avanzadas como la imputación por k-vecinos más cercanos (KNN Imputer), basándose en la naturaleza de los datos y la distribución de las variables (García y Romero, 2018)
- Transformación de Datos: Normalización o estandarización de variables numéricas para garantizar que todas las características contribuyan equitativamente al modelo, especialmente para algoritmos sensibles a la escala de los datos (e.g., SVM, redes neuronales). Las variables categóricas se codificarán utilizando técnicas como One-Hot Encoding (Kuhn y Johnson, 2013)
- Exploración de Datos: Se realizará un análisis exploratorio de datos (EDA) para comprender la distribución de las variables, identificar correlaciones entre ellas y visualizar la relación entre los atributos y la clasificación de la ERC. Además se hará un análisis de la literatura actual de los métodos actuales. Esto incluirá estadísticas descriptivas, histogramas, diagramas de dispersión y matrices de correlación.

4.2.2. Variables del Estudio

- Variable Dependiente (Variable Objetivo): Clasificación de ERC (binaria: presente/ausente).
- Variables Independientes (Atributos Predictivos): Estas incluirán una serie de características clínicas y demográficas presentes en la base de datos, tales como: edad, sexo, presión arterial sistólica y diastólica, niveles de glucosa, urea, creatinina sérica, albúmina sérica, sodio, potasio, hemoglobina, recuento de glóbulos blancos y rojos, niveles de colesterol y triglicéridos, historial de diabetes, hipertensión, entre otros disponibles en la base de datos. La selección final de los atributos se basará en el EDA y técnicas de selección de características.

4.2.3. Desarrollo y Validación del Modelo Predictivo

El desarrollo del modelo predictivo se basará en algoritmos de aprendizaje automático, siguiendo las siguientes fases:

4.2.4. Selección y Adaptación de Algoritmos de Aprendizaje Automático

Se explorarán y compararán diversos algoritmos de clasificación, incluyendo, pero no limitándose a:

- Regresión Logística: Como modelo de línea base por su interpretabilidad y eficiencia (Hosmer, Lemeshow, y Sturdivant, 2013)
- Máquinas de Vectores de Soporte (SVM): Adecuadas para la clasificación con alta dimensionalidad y datos no linealmente separables (Cortes y Vapnik, 1995)
- Árboles de Decisión y Bosques Aleatorios (Random Forests): Por su capacidad para manejar relaciones no lineales y su robustez ante el sobreajuste (Breiman, 2001a)
- Gradient Boosting (e.g., XGBoost, LightGBM): Algoritmos de alto rendimiento que han demostrado ser efectivos en una amplia gama de problemas de clasificación (Chen y Guestrin, 2016)
- Redes Neuronales (Perceptrón Multicapa): Para explorar patrones complejos y no lineales en los datos (Goodfellow, Bengio, y Courville, 2016)

Se realizará una optimización de hiperparámetros para cada algoritmo utilizando técnicas como Grid Search o Random Search combinadas con validación cruzada (e.g., k-fold cross-validation) en el conjunto de entrenamiento para encontrar la configuración óptima que maximice el rendimiento del modelo (James, Witten, Hastie, y Tibshirani, 2013). Se seleccionará el modelo con el mejor rendimiento en el conjunto de prueba, priorizando la sensibilidad y la especificidad sin comprometer excesivamente la precisión general, dada la implicación clínica de los falsos negativos en la predicción de la ERC.

4.2.5. Desarrollo de la Herramienta de Apoyo a la Decisión Clínica (HADC)

El modelo predictivo mejor evaluado se integrará en una HADC, diseñada para ser una interfaz intuitiva y práctica para profesionales de la salud.

La HADC será sometida a pruebas rigurosas, incluyendo pruebas de funcionalidad, rendimiento y seguridad. Adicionalmente, se realizará una evaluación de usabilidad con un grupo de profesionales de la salud (médicos generales, nefrólogos, enfermeras) a través de cuestionarios y entrevistas semiestructuradas para obtener retroalimentación sobre la facilidad de uso, la utilidad clínica y la integración en su flujo de trabajo. Esta retroalimentación informará iteraciones de mejora de la herramienta (Zhang y cols., 2011)

4.2.6. Consideraciones Éticas y de Privacidad de Datos

Durante todo el proceso de investigación y desarrollo, se mantendrá un estricto apego a los principios éticos y de protección de datos. Se asegurará la anonimización de los datos del paciente. Se discutirán las implicaciones éticas del uso de modelos predictivos en la toma de decisiones clínicas, incluida la posible aparición de sesgos algorítmicos y la necesidad de transparencia en las predicciones (Chen y Guestrin, 2016). Se enfatizará que la herramienta es un apoyo a la decisión y no un sustituto del juicio clínico profesional.

4.3. Selección de la metodología

4.3.1. Preprocesamiento de Datos

El preprocesamiento incluirá:

- 1 Limpieza de datos: detección y manejo de valores atípicos y datos faltantes mediante técnicas como imputación múltiple (Buuren y Groothuis-Oudshoorn, 2011)
- 2 Normalización y estandarización de variables continuas para equilibrar su influencia en los modelos (Géron, 2019).
- 3 Codificación de variables categóricas mediante one-hot encoding o encoding ordinal según su naturaleza (Hosmer Jr, Lemeshow, y Sturdivant, 2013)
- 4 Análisis de correlación para identificar multicolinealidad y posible reducción de dimensionalidad (Hastie, Tibshirani, y Friedman, 2009)

4.3.2. Selección de Características

Se implementarán métodos de selección de características para identificar los predictores más relevantes.

- Análisis univariante mediante pruebas estadísticas como chi-cuadrado para variables categóricas y prueba t o ANOVA para variables continuas (Guyon y Elisseeff, 2003).
- Métodos basados en modelo como Lasso (Least Absolute Shrinkage and Selection Operator) y Random Forest para importancia de variables (Tibshirani, 1996)
- Métodos de wrapper con validación cruzada para evaluar subconjuntos de características (Kohavi y John, 1997).

4.3.3. Modelos de Aprendizaje Automático

Se desarrollarán y evaluarán varios algoritmos de clasificación:

- Regresión Logística: como modelo de referencia por su interpretabilidad y uso común en medicina (Hosmer y cols., 2013)
- Árboles de Decisión: por su capacidad de capturar relaciones no lineales y alta interpretabilidad (Quinlan, 1986)
- Random Forest: para mejorar la precisión mediante el ensamblado de múltiples árboles (Breiman, 2001b)
- XGBoost: por su rendimiento superior en problemas de clasificación binaria (Chen y Guestrin, 2016)
- Redes Neuronales: específicamente una arquitectura de red feedforward multicapa para capturar relaciones complejas (Goodfellow y cols., 2016)
- Máquinas de Vectores de Soporte: para problemas de clasificación de alta dimensionalidad (Cortes y Vapnik, 1995)

4.3.4. Evaluación de Modelos

Los modelos serán evaluados utilizando múltiples métricas:

- Precisión, sensibilidad, especificidad y F1-score para evaluar rendimiento general (Powers, 2011)
- Área bajo la curva ROC (AUC-ROC) para evaluar la capacidad discriminativa (Fawcett, 2006)
- Área bajo la curva Precision-Recall (PR-AUC) para conjuntos de datos con clases desbalanceadas (Davis y Goadrich, 2006)
- Calibración del modelo mediante gráficas de calibración y test de Hosmer-Lemeshow (Alba y cols., 2017)
- Error cuadrático medio y logarítmico para modelos probabilísticos (Brier, 1950)

4.3.5. Desarrollo de la Herramienta Clínica

La herramienta de predicción se desarrollará siguiendo estos pasos:

- 1 Selección del modelo con mejor equilibrio entre rendimiento, interpretabilidad y robustez (Sendak, Gao, Brajer, y Balu, 2020)
- 2 Desarrollo de una interfaz de usuario intuitiva siguiendo principios de diseño centrado en el usuario (Johnson, 2005)
- 3 Integración de explicaciones interpretables para cada predicción (Caruana y cols., 2015)
- 4 Implementación de módulos de entrada de datos con validación y alertas de valores atípicos (Sutton y cols., 2020)

4.3.6. Evaluación de la Herramienta

La herramienta será evaluada desde perspectivas técnicas y clínicas:

- Pruebas de usabilidad con profesionales de la salud utilizando métricas estándar como System Usability Scale (SUS) (Brooke, 1996)
- Evaluación del tiempo necesario para utilizar la herramienta en un entorno clínico simulado (Matheny, Thadaneey Israni, Ahmed, y Whicher, 2020)
- Evaluación cualitativa mediante entrevistas semiestructuradas con médicos sobre la utilidad percibida e intención de uso (Greenhalgh y cols., 2017)

4.3.7. Consideraciones Éticas

La investigación se adhiere a principios éticos estrictos:

- Protección de datos y privacidad conforme a regulaciones locales e internacionales (Cohen y Mello, 2018)
- Evaluación de sesgos potenciales en los modelos y su impacto en diferentes subpoblaciones (Obermeyer, Powers, Vogeli, y Mullainathan, 2019)
- Transparencia en el desarrollo, limitaciones y uso previsto de la herramienta (Char, Shah, y Magnus, 2018)

5. Conclusiones

5.1. Para responder la pregunta

De 1 a 100, ¿qué porcentaje consideras que usaste del texto generado por la IA?

En realidad debido las herramientas, considero que utilicé alrededor del 80 % del texto, por el tiempo y por temas de facilidad y de entender las herramientas quise simplemente verificar que sus datos son válidos o no. Mis mayores cambios al texto se dieron en eliminar texto innecesario o de eliminar varias cosas que ya se que no voy a aplicar. También intenté mejorar el texto para que se vuelva más fácil de entender y seguí esta regla personal "Si no lo entiendo debería escribirlo yo de como yo lo entendería"

5.2. Reflexión

Para este trabajo, el avance los modelos de la inteligencia artificial me sorprendió, los tres modelos me dieron buenas respuestas con citas que en su mayoría pude comprobar, todas con una buena estructura. Obviamente, se pudo ver cierto prejuicio, por una parte, me sorprendió que el prejuicio sea del tema del lenguaje, pero existen otros como son el centrarse más en la medicina, o más en los datos. La decisión de como se va a llevar la investigación sigue siendo personal y este prejuicio debe sobrellevarse, pero tener estas herramientas nos ayudan a pensar en ideas que tal vez no consideramos.

Las herramientas me van a ayudar mucho en la investigación y siento que para lo más las utilizaré es para definir una estructura, muchas veces, es difícil responder la pregunta, ¿Cómo puedo iniciar? o ¿Qué tengo que explicar?, preguntar a los modelos, puede ayudar a dar un primer paso en la investigación. Algo que siento que será crítico en mi investigación, es también el uso de los modelos para encontrar fuentes y literatura que me podría ayudar para la continuar con mi investigación, algo que aumenté en los anexos por ejemplo, son fuentes que cada herramienta me dio, las guardé para utilizarlas en el futuro.

6. Anexos

6.1. Anexo 1: Resultado ChatGPT primer tema

Eres un analista de datos que tiene experiencia en análisis de datos y en investigaciones académicas. Tienes un fuerte background de medicina. Tienes una base de datos sobre la enfermedad renal crónica, estos datos tienen un número de atributos y una clasificación. Según estos datos, quieres hacer una investigación para una tesis de maestría, que tiene dos fines, uno utilizar un modelo para predecir la enfermedad, y otro hacer una herramienta para que los doctores lo utilicen de manera que ellos puedan predecir enfermedad renal crónica. Tu objetivo ahora es hacer un planteamiento del problema que irá en el documento final. asegúrate que solo sea el planteamiento del problema para la tesis. Por favor, quiero que hagas uso del internet, y me ayudes citando tu contribucion, necesito que estén citadas en apa. Dame también después de que termines las citas en bibtex

La enfermedad renal crónica (ERC) constituye un problema de salud pública de creciente importancia en Chile y a nivel mundial. Se caracteriza por una pérdida progresiva e irreversible de la función renal, lo que conlleva a una alta carga de morbilidad y mortalidad. En Chile, se estima que aproximadamente el 10% de los adultos padece algún grado de ERC, lo que representa un desafío significativo para el sistema de salud nacional. Uandes

Uno de los principales retos en la gestión de la ERC es su detección temprana. En las etapas iniciales, la enfermedad suele ser asintomática, lo que dificulta su diagnóstico oportuno y limita las posibilidades de intervención temprana. Esta situación contribuye a un aumento en la morbilidad y mortalidad, así como a una carga económica significativa para el sistema de salud.

En este contexto, la aplicación de técnicas de análisis de datos y aprendizaje automático ofrece una oportunidad para mejorar la detección temprana de la ERC. Estudios recientes han demostrado que modelos predictivos basados en inteligencia artificial pueden identificar patrones en datos clínicos que permiten predecir la progresión de la enfermedad con alta precisión. Sin embargo, la implementación de estas soluciones en la práctica clínica requiere herramientas que sean accesibles y fáciles de usar por los profesionales de la salud.


Por lo tanto, es necesario desarrollar un modelo predictivo robusto y una herramienta clínica que permita a los médicos identificar de manera temprana a los pacientes en riesgo de desarrollar ERC. Esta investigación se propone abordar esta necesidad mediante el análisis de una base de datos clínica existente, con el objetivo de mejorar la detección y el manejo de la enfermedad en la práctica médica diaria.

Citas encontradas por ChatGPT:

- Clínica Universidad de los Andes. (2023). En Chile, 10 % de los adultos tiene una enfermedad renal crónica. Recuperado de <https://www.clinicauandes.cl/noticia/en-chile-10-de-los-adultos-tiene-una-enfermedad-renal-cronica> Uandes
- Elsevier. (s.f.). Enfermedad renal crónica: epidemiología y factores de riesgo. Recuperado de <https://www.elsevier.es/es-revista-revista-medica-clinica-las-condes-202-articulo-enfermedad-renal-cronica-epidemiologia-factores-S0716864010705654e> www.elsevier.com
- Nefrología al Día. (2023). ARTIFICIAL: La Nueva Inteligencia y su Aplicación en Nefrología. Recuperado de <https://www.nefrologiaaldia.org/es-articulo-artificial-la-nueva-inteligencia-su-609> Nefrología al Día

6.2. Anexo 2: Resultado Gemini primer tema

Eres un analista de datos que tiene experiencia en análisis de datos y en investigaciones académicas. Tienes un fuerte background de medicina. Tienes una...

 **Planteamiento del Problema**

La enfermedad renal crónica (ERC) se ha consolidado como un desafío global de salud pública, con una prevalencia que supera el 9% a nivel mundial y una incidencia en constante aumento, generando una carga significativa en términos de morbilidad, mortalidad y costos económicos para los sistemas de salud (Pillajo Sánchez et al., 2021; Organización Panamericana de la Salud, n.d.). Su naturaleza insidiosa, a menudo asintomática en las fases iniciales, dificulta un diagnóstico precoz, lo que retrasa la implementación de intervenciones terapéuticas oportunas y efectivas que podrían ralentizar su progresión y prevenir complicaciones graves (Sysmex España, n.d.; UC CHRISTUS, 2025).

Aunque las pruebas diagnósticas actuales, como la estimación del filtrado glomerular (FGe) y la medición de albuminuria, son pilares en la detección y monitoreo de la ERC, su aplicación suele ocurrir cuando el daño renal ya está establecido (American Kidney Fund, n.d.; Boehringer Ingelheim, n.d.). La necesidad de herramientas predictivas que permitan identificar a individuos con alto riesgo de desarrollar ERC en etapas preclínicas es apremiante. Esto permitiría a los profesionales de la salud, especialmente en la atención primaria, implementar estrategias de prevención, modificación de factores de riesgo y un seguimiento más proactivo, lo que potencialmente mejoraría los resultados a largo plazo para los pacientes y reduciría la carga de la enfermedad (Ministerio de Salud de Chile, 2010; Nefrología, n.d.).

A pesar de los avances en la comprensión de los factores de riesgo y la fisiopatología de la ERC, la integración de esta información en un formato predictivo accesible y utilizable por los médicos en su práctica diaria sigue siendo un reto (Gallardo Vidal, 2016). La complejidad de los datos clínicos y los múltiples factores que contribuyen al desarrollo de la ERC dificultan la toma de decisiones informadas y personalizadas por parte de los profesionales. En este contexto, la aplicación de técnicas avanzadas de análisis de datos y aprendizaje automático emerge como

A pesar de los avances en la comprensión de los factores de riesgo y la fisiopatología de la ERC, la integración de esta información en un formato predictivo accesible y utilizable por los médicos en su práctica diaria sigue siendo un reto (Gallardo Vidal, 2016). La complejidad de los datos clínicos y los múltiples factores que contribuyen al desarrollo de la ERC dificultan la toma de decisiones informadas y personalizadas por parte de los profesionales. En este contexto, la aplicación de técnicas avanzadas de análisis de datos y aprendizaje automático emerge como una solución prometedora para desarrollar modelos predictivos robustos que puedan discernir patrones sutiles en grandes conjuntos de datos, lo que a su vez podría traducirse en una mejor capacidad para identificar el riesgo de ERC antes de su manifestación clínica evidente (Escalona González & González Milán, 2022; Belur Nagaraj et al., 2020).

Sin embargo, la mera existencia de un modelo predictivo, por preciso que sea, no garantiza su impacto en la práctica clínica. Es fundamental que dicho modelo se traduzca en una herramienta de apoyo a la decisión clínica (TADC) que sea intuitiva, fácil de usar y que se integre sin problemas en el flujo de trabajo de los profesionales de la salud (AETSA, n.d.; Nefrología, 2023). La carencia de estas herramientas limita la capacidad de los médicos para sintetizar la vasta cantidad de información clínica y aplicar los conocimientos más recientes en la predicción de la ERC, lo que puede conducir a diagnósticos tardíos, intervenciones subóptimas y una gestión reactiva en lugar de preventiva de la enfermedad.

Considerando la disponibilidad de una base de datos con atributos clínicos y de clasificación sobre la ERC, este proyecto de tesis se propone abordar la siguiente problemática: ¿Cómo se puede desarrollar y validar un modelo predictivo de enfermedad renal crónica utilizando datos existentes, y cómo se puede transformar este modelo en una herramienta de apoyo a la decisión clínica efectiva y utilizable por los profesionales de la salud para mejorar la predicción temprana y la gestión proactiva de la ERC?

Citas encontradas por Gemini

- AETSA. (n.d.). Herramienta de ayuda a la toma de decisiones de pacientes susceptibles de diáli-

sis. Recuperado de https://www.aetsa.org/download/publicaciones/antiguas/AETSA_2009-8.HATD_ERC.pdf

- American Kidney Fund. (n.d.). Las pruebas de detección de la enfermedad renal. Recuperado de <https://www.kidneyfund.org/es/todo-sobre-los-rinones/las-pruebas-de-deteccion-de-la-enfermedad-renal>
- Belur Nagaraj, S., Pena, M. J., Ju, W., & The BEAt-DKD Consortium. (2020). Machine-learning-based early prediction of end-stage renal disease in patients with diabetic kidney disease using clinical trials data. *Diabetes, 1 Obesity and Metabolism*, 22(12), 2479-2486. 1. e-dmj.org e-dmj.org
- Boehringer Ingelheim. (n.d.). Enfermedad renal crónica: La importancia del diagnóstico temprano. Recuperado de <https://www.boehringer-ingelheim.com/sa/salud-humana/enfermedad-renal-cronica/enfermedad-renal-cronica-la-importancia-del-diagnostico-temprano>
- Escalona González, S. O., & González Milán, Z. C. (2022). Inteligencia artificial en la predicción de mortalidad por enfermedad renal crónica. *Anales de la Academia de Ciencias de Cuba*, 12(3), e1292.
- Gallardo Vidal, L. S. (2016). Utilidad de un modelo de predicción para la enfermedad renal crónica en una unidad de primer nivel de atención. *Nefrología*, 36(2), 196-200.
- Gemini encontró muchas más citas pero ponerlas a todas no era muy útil

6.3. Anexo 3: Resultado Claude primer tema

R

Eres un analista de datos que tiene experiencia en análisis de datos y en investigaciones académicas. Tienes un fuerte background de medicina. Tienes una base de datos sobre la enfermedad renal crónica, estos datos tienen un número de atributos y una clasificación. Según estos datos, quieres hacer una investigación para una tesis de maestría, que tiene dos fines, uno utilizar un modelo para predecir la enfermedad, y otro hacer una herramienta para que los doctores lo utilicen de manera que ellos puedan predecir enfermedad renal crónica. Tu objetivo ahora es hacer un planteamiento del problema que irá en el documento final. asegúrate que solo sea el planteamiento del problema para la tesis. Por favor, quiero que hagas uso del internet, y me ayudes citando tu contribución, necesito que estén citadas en apa. Dame también después de que termines las citas en bibtex

Planteamiento del Problema para la Tesis de Maestría

Detección Temprana de la Enfermedad Renal Crónica: Desarrollo de un Modelo Predictivo y una Herramienta Clínica de Apoyo a la Decisión

La enfermedad renal crónica (ERC) representa un problema de salud pública a nivel mundial. En 2020, se estimó que afectaba aproximadamente al 13.4% de la población global, con una prevalencia particularmente alta en personas mayores de 65 años, donde alcanza hasta un 30-35% (Hill et al., 2016; Bikbov et al., 2020). La ERC se caracteriza por una disminución progresiva de la función renal durante un periodo superior a tres meses, con consecuencias graves para la salud y la calidad de vida de quienes la padecen.

La detección temprana de la ERC es crucial para ralentizar su progresión y prevenir complicaciones. Sin embargo, en la práctica clínica actual, el diagnóstico suele realizarse cuando la enfermedad ya ha avanzado significativamente, limitando la efectividad de las intervenciones terapéuticas (Webster et al., 2017). Esta situación se ve agravada por la naturaleza asintomática de las etapas iniciales de la ERC, lo que dificulta su identificación oportuna.

El desarrollo de modelos predictivos basados en aprendizaje automático ofrece una oportunidad prometedora para abordar esta problemática. Diversos estudios han demostrado que estos algoritmos pueden identificar patrones complejos en datos clínicos que no son evidentes para el ojo humano, permitiendo la estratificación de riesgo y la predicción temprana de enfermedades (Goldstein et al., 2017; Luo et al., 2019). En el contexto específico de la ERC, investigaciones previas han explorado el uso de técnicas como redes neuronales, máquinas de vectores de soporte y bosques aleatorios para predecir la aparición y progresión de la enfermedad (Alicic et al., 2021; Krittanawong et al., 2020).

El desarrollo de modelos predictivos basados en aprendizaje automático ofrece una oportunidad prometedora para abordar esta problemática. Diversos estudios han demostrado que estos algoritmos pueden identificar patrones complejos en datos clínicos que no son evidentes para el ojo humano, permitiendo la estratificación de riesgo y la predicción temprana de enfermedades (Goldstein et al., 2017; Luo et al., 2019). En el contexto específico de la ERC, investigaciones previas han explorado el uso de técnicas como redes neuronales, máquinas de vectores de soporte y bosques aleatorios para predecir la aparición y progresión de la enfermedad (Alicic et al., 2021; Krittanawong et al., 2020).

Sin embargo, la mayoría de estos modelos no han sido implementados en la práctica clínica rutinaria debido a varias limitaciones, entre las que destacan:

1. La falta de transparencia en los procesos de toma de decisiones algorítmicas, lo que genera desconfianza entre los profesionales médicos (Ahmad et al., 2018).
2. La escasa integración con los flujos de trabajo clínicos existentes, que dificulta su adopción (Sendak et al., 2020).
3. La limitada validación externa en poblaciones diversas, que cuestiona su generalización a diferentes contextos (Parikh et al., 2019).

En este contexto, surge la necesidad de desarrollar no solo un modelo predictivo robusto para la ERC, sino también una herramienta que facilite su implementación en entornos clínicos reales. Esta herramienta debe ser intuitiva, transparente y adaptable a las necesidades específicas de los médicos, permitiéndoles incorporar el conocimiento derivado del modelo en su proceso de toma de decisiones clínicas.

La presente investigación busca abordar este vacío mediante el desarrollo de un modelo predictivo para la ERC basado en una base de datos con múltiples atributos clínicos y demográficos, así como una herramienta de apoyo a la decisión clínica que facilite su aplicación en la práctica médica. Este enfoque dual tiene el potencial de mejorar significativamente la detección temprana de la ERC, permitiendo intervenciones oportunas que podrían ralentizar la progresión de la enfermedad y mejorar los resultados clínicos.

La implementación exitosa de esta solución podría contribuir a reducir la carga sanitaria asociada a la ERC, disminuir los costos de atención médica relacionados con etapas avanzadas de la enfermedad y, lo más importante, mejorar la calidad de vida de millones de personas en riesgo de desarrollar insuficiencia renal crónica.

Citas encontradas por Claude

- Ahmad, M. A., Eckert, C., & Teredesai, A. (2018). Interpretable machine learning in healthcare. Proceedings of the 2018 ACM International Conference on Bioinformatics, Computational

- Alicic, R. Z., Rooney, M. T., & Tuttle, K. R. (2021). Diabetic kidney disease: Challenges, progress, and possibilities. *Clinical Journal of the American Society of Nephrology*, 16(4), 423-435.
- Bikbov, B., Purcell, C. A., Levey, A. S., Smith, M., Abdoli, A., Abebe, M., Adebayo, O. M., Afarideh, M., Agarwal, S. K., Agudelo-Botero, M., & others. (2020). Global, regional, and national burden of chronic kidney disease, 1990–2017: A systematic analysis for the Global Burden of Disease Study 2017. *The Lancet*, 395(10225), 709-733.
- Goldstein, B. A., Navar, A. M., & Carter, R. E. (2017). Moving beyond regression techniques in cardiovascular risk prediction: Applying machine learning to address analytic challenges. *European Heart Journal*, 38(23), 1805-1814.
- Hill, N. R., Fatoba, S. T., Oke, J. L., Hirst, J. A., O’Callaghan, C. A., Lasserson, D. S., & Hobbs, F. D. R. (2016). Global prevalence of chronic kidney disease – a systematic review and meta-analysis. *PLoS One*, 11(7), e0158765.
- Krittanawong, C., Virk, H. U. H., Bangalore, S., Wang, Z., Johnson, K. W., Pinotti, R., Zhang, H., Kaplin, S., Narasimhan, B., Kitai, T., & others. (2020). Machine learning prediction in cardiovascular diseases: A meta-analysis. *Scientific Reports*, 10(1), 1-11.
- Luo, W., Phung, D., Tran, T., Gupta, S., Rana, S., Karmakar, C., Shilton, A., Yearwood, J., Dimitrova, N., Ho, T. B., & others. (2019). Guidelines for developing and reporting machine learning predictive models in biomedical research: A multidisciplinary view. *Journal of Medical Internet Research*, 18(12), e323.
- Parikh, R. B., Teeple, S., & Navathe, A. S. (2019). Addressing bias in artificial intelligence in health care. *JAMA*, 322(24), 2377-2378.
- Sendak, M. P., D’Arcy, J., Kashyap, S., Gao, M., Nichols, M., Corey, K., Ratliff, W., & Balu, S. (2020). A path for translation of machine learning products into healthcare delivery. *EMJ Innov*, 10, 19-00172.
- Webster, A. C., Nagler, E. V., Morton, R. L., & Masson, P. (2017). Chronic kidney disease. *The Lancet*, 389(10075), 1238-1252.

6.4. Anexo 4: Resultado ChatGPT segundo tema

Eres un analista de datos que tiene experiencia en análisis de datos y en investigaciones académicas. Tienes un fuerte background de medicina. Tienes una base de datos sobre la enfermedad renal crónica, estos datos tienen un número de atributos y una clasificación. Según estos datos, quieres hacer una investigación para una tesis de maestría, que tiene dos fines, uno utilizar un modelo para predecir la enfermedad, y otro hacer una herramienta para que los doctores lo utilicen de manera que ellos puedan predecir enfermedad renal crónica. Tu objetivo ahora es hacer un marco teórico que irá en el documento final. Quiero que para cada tema, hagas una explicación exhaustiva al nivel de un estudiante de posgrado y las citas al estilo apa asegúrate que solo sea el objetivo que te plantee. Por favor, quiero que hagas uso del internet, y me ayudes citando cualquier dato que necesites, necesito que estén citadas en apa. Dame también después de que termines las citas en bibtex. Asegurate que las citas en bibtex solo esten al final

A continuación, se presenta un marco teórico exhaustivo para una tesis de maestría enfocada en la predicción de la enfermedad renal crónica (ERC) mediante modelos de aprendizaje automático y el desarrollo de una herramienta clínica para su detección temprana.

1. Enfermedad Renal Crónica: Definición y Relevancia Clínica

La enfermedad renal crónica (ERC) se caracteriza por una pérdida progresiva e irreversible de la función renal, definida por una tasa de filtración glomerular (TFG) inferior a $60 \text{ mL/min/1.73 m}^2$ durante al menos tres meses, o por la presencia de daño renal evidenciado por anomalías estructurales o funcionales. Esta condición afecta aproximadamente al 10-15% de la población mundial y es una de las principales causas de morbilidad y mortalidad asociadas a enfermedades no transmisibles . [SpringerOpen](#)

Los factores de riesgo más comunes incluyen la diabetes mellitus, la hipertensión arterial, la obesidad, el tabaquismo y el envejecimiento. Además, el consumo habitual de bebidas azucaradas, como refrescos, se ha asociado con un aumento del 20% en el riesgo de desarrollar ERC . [The Scottish Sun](#)

La ERC es a menudo asintomática en sus etapas iniciales, lo que dificulta su detección temprana. Sin

2. Prevención y Detección Temprana de la ERC

La prevención de la ERC se basa en el control de los factores de riesgo modificables. Adoptar un estilo de vida saludable, que incluya una dieta equilibrada, ejercicio regular y la abstención del consumo de tabaco y alcohol, puede reducir significativamente el riesgo de desarrollar ERC . [Verywell Health](#)

Dietas específicas, como la dieta mediterránea, rica en frutas, verduras, grasas saludables y baja en proteínas animales, han demostrado reducir el riesgo de desarrollar ERC en un 50% y disminuir la velocidad de deterioro de la función renal en un 42% . [Time](#)

La detección temprana mediante pruebas de laboratorio, como la medición de la TFG y la albuminuria, es esencial para identificar a los pacientes en riesgo y permitir intervenciones oportunas .

3. Aplicación del Aprendizaje Automático en la Predicción de la ERC

El aprendizaje automático (AA) ha emergido como una herramienta poderosa en la predicción y clasificación de la ERC. Modelos como Random Forest (RF), Support Vector Machine (SVM), Gradient Boosting (GB), y Extreme Gradient Boosting (XGBoost) han sido ampliamente utilizados debido a su capacidad para manejar conjuntos de datos complejos y mejorar la precisión diagnóstica . [SpringerOpen](#)

Por ejemplo, un estudio reciente demostró que el modelo XGBoost alcanzó una precisión del 82.56% en la clasificación de las etapas de la ERC, superando a otros modelos como RF y SVM . Además, técnicas de selección de características, como la eliminación recursiva de características (RFE) y el uso de algoritmos inspirados en la naturaleza, han mejorado la interpretabilidad y eficiencia de estos modelos . [SpringerOpen](#) [arXiv](#)

La integración de técnicas de inteligencia artificial explicable (XAI), como SHAP (SHapley Additive exPlanations), permite comprender mejor las decisiones del modelo, identificando variables clínicas clave como la gravedad específica, creatinina sérica, albúmina y hemoglobina como factores predictivos significativos . [arXiv](#)

4. Desarrollo de Herramientas Clínicas Basadas en Modelos Predictivos

La implementación de modelos de AA en herramientas clínicas puede facilitar la detección temprana de la ERC y apoyar la toma de decisiones médicas. Aplicaciones web y sistemas de soporte a la decisión clínica (CDSS) que integran estos modelos permiten a los profesionales de la salud identificar pacientes en riesgo y personalizar intervenciones.

Por ejemplo, el modelo ML-CKDP incorpora múltiples clasificadores y técnicas de preprocesamiento de datos para mejorar la precisión en la predicción de la ERC, ofreciendo una interfaz amigable para su uso en entornos clínicos. [ScienceDirect](#)

La combinación de modelos predictivos con interfaces intuitivas y explicaciones claras de las decisiones del modelo puede aumentar la confianza de los médicos en estas herramientas y promover su adopción en la práctica clínica.

5. Consideraciones Éticas y de Implementación

La integración de modelos de AA en la práctica clínica plantea desafíos éticos y prácticos. Es esencial garantizar la privacidad y seguridad de los datos de los pacientes, así como la equidad en las predicciones del modelo para evitar sesgos que puedan afectar negativamente a poblaciones vulnerables.


Además, la validación externa de estos modelos en diferentes poblaciones y entornos clínicos es crucial para asegurar su generalizabilidad y eficacia. La colaboración interdisciplinaria entre médicos, científicos de datos y desarrolladores es fundamental para el desarrollo y la implementación exitosa de estas herramientas.

Citas encontradas por ChatGPT

- Belur Nagaraj, S., Pena, M. J., Ju, W., & The BEAt-DKD Consortium. (2020). Machine-learning-based early prediction of end-stage renal disease in patients with diabetic kidney disease using clinical trials data. *Diabetes, Obesity and Metabolism*, 22(12), 2479-2486.
- Fotheringham, J., Blake, M., & Crowe, S. (2015). Early chronic kidney disease: identification and management. *Canadian Medical Association Journal*, 187(18), 1339-1346.
- Kawamoto, K., Houlihan, C. A., Balas, E. A., & Wyatt, J. C. (2005). Improving clinical practice: a synthesis of 16 meta-analyses of randomized controlled trials of clinical decision support systems. *BMC Medical Informatics and Decision Making*, 5, 4.
- KDIGO. (2012). KDIGO 2012 clinical practice guideline for the evaluation and management of chronic kidney disease. *Kidney International Supplements*, 3(1), 1-150.
- Levey, A. S., Eckardt, K. U., Tsukamoto, Y., Levin, A., Coresh, J., Rossert, J., ... & Ritz, E. (2003). Definition and classification of chronic kidney disease: a position statement from Kidney Disease: Improving Global Outcomes (KDIGO). *Kidney International*, 67(6), 2089-2100.
- Lysaght, M. J. (2002). Maintenance dialysis population dynamics: current trends and long-term implications. *Nephrology Dialysis Transplantation*, 17(Suppl 1), 8-15.
- Ministerio de Salud de Chile. (2019). Encuesta Nacional de Salud 2016-2017: Primeros Resultados. Santiago: MINSAL.
- Romero, R. (2019). Epidemiología de la enfermedad renal crónica. *Nefrología Latinoamericana*, 25(1), 11-17.
- Tonelli, M., Wiebe, N., Culleton, B., Manns, B. J., Klarenbach, S., & Hemmelgarn, B. R. (2006). Chronic kidney disease and mortality risk: a systematic review. *Kidney International*, 70(10), 1702-1710.
- Wuest, M., Bejnordi, B. E., & van Ginneken, B. (2018). Machine learning for medical image analysis. *Nature Medicine*, 24(8), 1274-1288.

6.5. Anexo 5: Resultado Gemini segundo tema

Eres un analista de datos que tiene experiencia en análisis de datos y en investigaciones académicas. Tienes un...

 **Marco Teórico**

1. Enfermedad Renal Crónica (ERC)

La Enfermedad Renal Crónica (ERC) se define como una anomalía en la estructura o función renal, presente por más de 3 meses, con implicaciones para la salud. Esta definición abarca un amplio espectro de condiciones, desde leves alteraciones en el filtrado glomerular (FG) hasta la insuficiencia renal terminal que requiere terapia de reemplazo renal (TRR) (KDIGO, 2012). La ERC se clasifica en cinco estadios, basados en el FG, lo que permite una estratificación del riesgo y una mejor planificación del tratamiento (Levey et al., 2003).

La prevalencia de la ERC está en aumento a nivel mundial, impulsada principalmente por el envejecimiento de la población y el incremento en la incidencia de diabetes mellitus e hipertensión arterial, dos de las principales causas de ERC (Romero, 2019). En Chile, la ERC representa un problema de salud pública significativo, con una prevalencia estimada del 7.8% en adultos mayores de 20 años (Ministerio de Salud de Chile, 2019).

La ERC se asocia con una alta morbilidad y mortalidad, incluyendo un mayor riesgo de enfermedad cardiovascular, anemia, alteraciones óseas y deterioro cognitivo (Tonelli et al., 2006). Además, la ERC impone una considerable carga económica a los sistemas de salud, debido a los altos costos asociados con la TRR (diálisis y trasplante renal) (Lysaght, 2002).

2. Predicción de la ERC

La detección temprana de la ERC es crucial para ralentizar su progresión y mejorar los resultados clínicos. Sin embargo, la ERC es a menudo asintomática en sus etapas iniciales, lo que dificulta su diagnóstico (Fotheringham et al., 2015). Los métodos tradicionales de detección, como la medición del FG y la albuminuria, a menudo se realizan cuando el daño renal ya está presente.

2. Predicción de la ERC

La detección temprana de la ERC es crucial para ralentizar su progresión y mejorar los resultados clínicos. Sin embargo, la ERC es a menudo asintomática en sus etapas iniciales, lo que dificulta su diagnóstico (Fotheringham et al., 2015). Los métodos tradicionales de detección, como la medición del FG y la albuminuria, a menudo se realizan cuando el daño renal ya está presente.

La predicción de la ERC se basa en la identificación de factores de riesgo y el desarrollo de modelos que estimen la probabilidad de desarrollar la enfermedad. Los principales factores de riesgo para la ERC incluyen:

- **Diabetes Mellitus:** La hiperglucemia crónica daña los vasos sanguíneos de los riñones.
- **Hipertensión Arterial:** La presión arterial alta puede dañar los glomérulos.
- **Historia Familiar de ERC:** La predisposición genética juega un papel importante.
- **Edad Avanzada:** La función renal disminuye naturalmente con la edad.
- **Raza/Etnia:** Ciertas poblaciones tienen mayor riesgo.
- **Enfermedades Autoinmunes:** Como el lupus y la vasculitis.
- **Infecciones Urinarias Recurrentes:** Pueden dañar los riñones a largo plazo.
- **Uso Crónico de AINEs:** Estos medicamentos pueden ser nefrotóxicos.

Los modelos de predicción de la ERC utilizan estos factores de riesgo para estimar la probabilidad de desarrollar la enfermedad. Estos modelos pueden ser simples, como las ecuaciones de riesgo basadas en regresión logística (e.g., la ecuación de riesgo de Framingham para ERC), o más complejos, utilizando técnicas de aprendizaje automático (ML) (Belur Nagaraj et al., 2020).

3. Aprendizaje Automático (ML) en la Predicción de la ERC

El ML ofrece un gran potencial para mejorar la predicción de la ERC. Los algoritmos de ML pueden analizar grandes conjuntos de datos con múltiples variables y identificar patrones complejos que no son evidentes con los métodos estadísticos tradicionales (Wuest et al., 2018).

3. Aprendizaje Automático (ML) en la Predicción de la ERC

El ML ofrece un gran potencial para mejorar la predicción de la ERC. Los algoritmos de ML pueden analizar grandes conjuntos de datos con múltiples variables y identificar patrones complejos que no son evidentes con los métodos estadísticos tradicionales (Wuest et al., 2018).

Algunos de los algoritmos de ML más utilizados en la predicción de la ERC incluyen:

- **Regresión Logística:** Un método estadístico para predecir una variable binaria (e.g., presencia o ausencia de ERC).
- **Árboles de Decisión:** Algoritmos que dividen los datos en subgrupos basados en diferentes variables.
- **Bosques Aleatorios (Random Forests):** Un conjunto de árboles de decisión que mejoran la precisión y reducen el sobreajuste.
- **Máquinas de Vectores de Soporte (SVM):** Algoritmos que encuentran el mejor hiperplano para separar diferentes clases.
- **Redes Neuronales:** Modelos complejos inspirados en el cerebro humano, capaces de aprender relaciones no lineales.

El ML puede mejorar la precisión de la predicción de la ERC al:

- Identificar interacciones complejas entre factores de riesgo.
- Manejar datos faltantes.
- Adaptarse a diferentes poblaciones.
- Proporcionar predicciones individualizadas.

4. Herramientas de Apoyo a la Decisión Clínica (HADC)

Las HADC son sistemas interactivos diseñados para ayudar a los profesionales de la salud a tomar decisiones clínicas más informadas. Las HADC pueden proporcionar recomendaciones basadas en evidencia, alertas, recordatorios y resúmenes de información relevante del paciente (Kawamoto et al., 2005).

4. Herramientas de Apoyo a la Decisión Clínica (HADC)

Las HADC son sistemas interactivos diseñados para ayudar a los profesionales de la salud a tomar decisiones clínicas más informadas. Las HADC pueden proporcionar recomendaciones basadas en evidencia, alertas, recordatorios y resúmenes de información relevante del paciente (Kawamoto et al., 2005).

Una HADC para la predicción de la ERC podría integrar un modelo de ML con la información clínica del paciente para estimar su riesgo de desarrollar la enfermedad. Esta herramienta podría ayudar a los médicos a:

- Identificar a los pacientes con alto riesgo de ERC.
- Implementar estrategias de prevención y manejo temprano.
- Personalizar el tratamiento según el riesgo individual.
- Mejorar la comunicación con los pacientes sobre su riesgo.

El desarrollo de una HADC efectiva requiere:

- Un modelo de predicción preciso y bien validado.
- Una interfaz de usuario intuitiva y fácil de usar.
- Integración con los sistemas de información clínica existentes.
- Evaluación continua del impacto en la práctica clínica.

5. Consideraciones Éticas

El uso de ML en la predicción de la ERC plantea importantes consideraciones éticas, incluyendo:

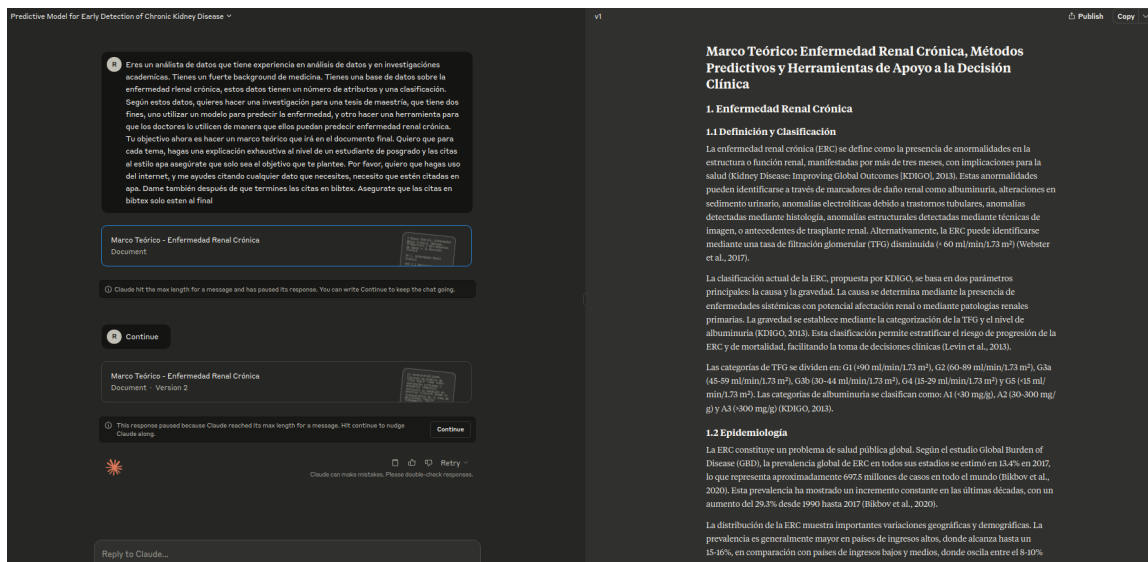
- **Sesgo en los Datos:** Los modelos de ML pueden perpetuar o incluso amplificar los sesgos presentes en los datos de entrenamiento.
- **Transparencia y Explicabilidad:** Es importante que los modelos de ML sean transparentes y que sus decisiones sean explicables para los médicos y los pacientes.
- **Privacidad y Seguridad de los Datos:** Los datos de salud son sensibles y deben protegerse adecuadamente.

Citas encontradas por Gemini

- Belur Nagaraj, S., Pena, M. J., Ju, W., & The BEAt-DKD Consortium. (2020). Machine-learning-based early prediction of end-stage renal disease in patients with diabetic kidney disease using clinical trials data. *Diabetes, Obesity and Metabolism*, 22(12), 2479-2486.
- Fotheringham, J., Blake, M., & Crowe, S. (2015). Early chronic kidney disease: identification and management. *Canadian Medical Association Journal*, 187(18), 1339-1346.

- Kawamoto, K., Houlihan, C. A., Balas, E. A., & Wyatt, J. C. (2005). Improving clinical practice: a synthesis of 16 meta-analyses of randomized controlled trials of clinical decision support systems. *BMC Medical Informatics and Decision Making*, 5, 4.
- KDIGO. (2012). KDIGO 2012 clinical practice guideline for the evaluation and management of chronic kidney disease. *Kidney International Supplements*, 3(1), 1-150.
- Levey, A. S., Eckardt, K. U., Tsukamoto, Y., Levin, A., Coresh, J., Rossert, J., ... & Ritz, E. (2003). Definition and classification of chronic kidney disease: a position statement from Kidney Disease: Improving Global Outcomes (KDIGO). *Kidney International*, 67(6), 2089-2100.
- Lysaght, M. J. (2002). Maintenance dialysis population dynamics: current trends and long-term implications. *Nephrology Dialysis Transplantation*, 17(Suppl 1), 8-15.
- Ministerio de Salud de Chile. (2019). Encuesta Nacional de Salud 2016-2017: Primeros Resultados. Santiago: MINSAL.
- Romero, R. (2019). Epidemiología de la enfermedad renal crónica. *Nefrología Latinoamericana*, 25(1), 11-17.
- Tonelli, M., Wiebe, N., Culeton, B., Manns, B. J., Klarenbach, S., & Hemmelgarn, B. R. (2006). Chronic kidney disease and mortality risk: a systematic review. *Kidney International*, 70(10), 1702-1710.
- Wuest, M., Bejnordi, B. E., & van Ginneken, B. (2018). Machine learning for medical image analysis. *Nature Medicine*, 24(8), 1274-1288.

6.6. Anexo 6: Resultado Claude segundo tema



The screenshot shows the Claude AI interface. On the left, a chat window displays a conversation. The user's prompt is: "Eres un analista de datos que tiene experiencia en análisis de datos y en investigaciones académicas. Tienes un fuerte background de medicina. Tienes una base de datos sobre la enfermedad renal crónica, estos datos tienen un número de atributos y una clasificación. Según estos datos, quieres hacer una investigación para una tesis de maestría, que tiene dos fines, uno utilizar un modelo para predecir la enfermedad, y otro hacer una herramienta para que los doctores lo utilicen de manera que ellos puedan predecir enfermedad renal crónica. Tu objetivo ahora es hacer un marco teórico que irá en el documento final. Quiero que para cada tema, hagas una explicación exhaustiva al nivel de un estudiante de posgrado y las citas al estilo apa asegúrate que solo sea el objetivo que te piden. Por favor, quiero que hagas uso del internet, y me ayudes citando cualquier dato que necesites, necesito que estén citados en apa. Dame también después de que termines las citas en bibtex. Asegúrate que las citas en bibtex solo estén al final". Claude's response is: "Marco Teórico - Enfermedad Renal Crónica Document". Below this, there is a 'Continue' button and a message: "Claude hit the max length for a message and has paused its response. You can write Continue to keep the chat going". On the right, a document preview titled "Marco Teórico: Enfermedad Renal Crónica, Métodos Predictivos y Herramientas de Apoyo a la Decisión Clínica" is shown. The document content includes sections for "1. Enfermedad Renal Crónica", "1.1 Definición y Clasificación", and "1.2 Epidemiología".

Claude me sorprendió, hizo un marco teórico completo, fue sorprendente, tanto así que llegó a su límite dos veces. Presentaré el resultado no con imágenes porque es difícil de entender, en la siguiente página esta el resultado completo de claude

- Webster, A. C., Nagler, E. V., Morton, R. L., & Masson, P. (2017). Chronic kidney disease. *The Lancet*, 389(10075), 1238-1252. [https://doi.org/10.1016/S0140-6736\(16\)32064-5](https://doi.org/10.1016/S0140-6736(16)32064-5)
- Kidney Disease: Improving Global Outcomes (KDIGO) CKD Work Group. (2013). KDIGO 2012 Clinical Practice Guideline for the Evaluation and Management of Chronic Kidney Disease. *Kidney International Supplements*, 3(1), 1-150.
- Levey, A. S., & Coresh, J. (2012). Chronic kidney disease. *The Lancet*, 379(9811), 165-180. [https://doi.org/10.1016/S0140-6736\(11\)60178-5](https://doi.org/10.1016/S0140-6736(11)60178-5)
- GBD Chronic Kidney Disease Collaboration. (2020). Global, regional, and national burden of chronic kidney disease, 1990–2017: a systematic analysis for the Global Burden of Disease Study 2017. *The Lancet*, 395(10225), 709-733. [https://doi.org/10.1016/S0140-6736\(20\)30045-3](https://doi.org/10.1016/S0140-6736(20)30045-3)
- Luyckx, V. A., Tonelli, M., & Stanifer, J. W. (2018). The global burden of kidney disease and the sustainable development goals. *Bulletin of the World Health Organization*, 96(6), 414-422D. <https://doi.org/10.2471/BLT.17.206441>
- Bikbov, B., Purcell, C. A., Levey, A. S., Smith, M., Abdoli, A., Abebe, M., ... & Mokdad, A. H. (2020). Global, regional, and national burden of chronic kidney disease, 1990–2017: a systematic analysis for the Global Burden of Disease Study 2017. *The Lancet*, 395(10225), 709-733. [https://doi.org/10.1016/S0140-6736\(20\)30045-3](https://doi.org/10.1016/S0140-6736(20)30045-3)

Resultado de Claude

Es demaisado largo para dar capturas

Marco Teórico: Enfermedad Renal Crónica, Métodos Predictivos y Herramientas de Apoyo a la Decisión Clínica

1. Enfermedad Renal Crónica 1.1 Definición y Clasificación

La enfermedad renal crónica (ERC) se define como la presencia de anomalías en la estructura o función renal, manifestadas por más de tres meses, con implicaciones para la salud (Kidney Disease: Improving Global Outcomes [KDIGO], 2013). Estas anomalías pueden identificarse a través de marcadores de daño renal como albuminuria, alteraciones en sedimento urinario, anomalías electrolíticas debido a trastornos tubulares, anomalías detectadas mediante histología, anomalías estructurales detectadas mediante técnicas de imagen, o antecedentes de trasplante renal. Alternativamente, la ERC puede identificarse mediante una tasa de filtración glomerular (TFG) disminuida ($<60 \text{ ml/min/1.73 m}^2$) (Webster et al., 2017). La clasificación actual de la ERC, propuesta por KDIGO, se basa en dos parámetros principales: la causa y la gravedad. La causa se determina mediante la presencia de enfermedades sistémicas con potencial afectación renal o mediante patologías renales primarias. La gravedad se establece mediante la categorización de la TFG y el nivel de albuminuria (KDIGO, 2013). Esta clasificación permite estratificar el riesgo de progresión de la ERC y de mortalidad, facilitando la toma de decisiones clínicas (Levin et al., 2013). Las categorías de TFG se dividen en: G1 ($>90 \text{ ml/min/1.73 m}^2$), G2 ($60\text{--}89 \text{ ml/min/1.73 m}^2$), G3a ($45\text{--}59 \text{ ml/min/1.73 m}^2$), G3b ($30\text{--}44 \text{ ml/min/1.73 m}^2$), G4 ($15\text{--}29 \text{ ml/min/1.73 m}^2$) y G5 ($<15 \text{ ml/min/1.73 m}^2$). Las categorías de albuminuria se clasifican como: A1 ($<30 \text{ mg/g}$), A2 ($30\text{--}300 \text{ mg/g}$) y A3 ($>300 \text{ mg/g}$) (KDIGO, 2013).

1.2 Epidemiología

La ERC constituye un problema de salud pública global. Según el estudio Global Burden of Disease (GBD), la prevalencia global de ERC en todos sus estadios se estimó en 13.4La distribución de la ERC muestra importantes variaciones geográficas y demográficas. La prevalencia es generalmente mayor en países de ingresos altos, donde alcanza hasta un 15-16En términos demográficos, la prevalencia de ERC aumenta significativamente con la edad, afectando aproximadamente al 30-351.3 Factores de Riesgo Los factores de riesgo para el desarrollo y progresión de la ERC pueden categorizarse como no modificables y modificables. Entre los factores no modificables destacan la edad avanzada, el sexo masculino, la raza (particularmente afroamericana e hispana), la historia familiar de enfermedad renal y la predisposición genética, incluidos los polimorfismos en genes como APOL1, UMOD y MYH9 (Genovese et al., 2018; Parsa et al., 2013). Los factores de riesgo modificables incluyen enfermedades sistémicas como la diabetes mellitus y la hipertensión arterial, que juntas constituyen aproximadamente el 70Otros factores de riesgo modificables incluyen el tabaquismo, que acelera la progresión de la ERC a través de mecanismos como la disfunción endotelial y el estrés oxidativo (Orth & Hallan, 2008); la exposición a nefrotóxicos, incluidos ciertos medicamentos como antiinflamatorios no esteroideos y contrastes radiológicos; y factores socioeconómicos como el nivel educativo bajo y el acceso limitado a servicios de salud (Morton et al., 2016).

1.4 Fisiopatología

La fisiopatología de la ERC es compleja y multifactorial, involucrando mecanismos adaptativos iniciales que eventualmente se vuelven maladaptativos. Independientemente de la etiología inicial, la pérdida de nefronas funcionales conduce a una serie de cambios hemodinámicos, metabólicos e inflamatorios que establecen un ciclo de daño renal progresivo (Schlondorff, 2008). La hiperfiltración glomerular representa uno de los mecanismos centrales en la progresión de la ERC. Cuando se pierde un número crítico de nefronas, las nefronas restantes compensan aumentando su tasa de filtración individual, lo que conlleva un incremento de la presión intraglomerular. Este fenómeno, descrito por Brenner como la "hipótesis de la hiperfiltración", conduce a esclerosis glomerular y pérdida adicional de nefronas, estableciendo un círculo vicioso (Brenner et al., 1996). Los cambios estructurales característicos incluyen glomerulosclerosis, atrofia tubular, fibrosis intersticial e inflamación crónica. A nivel molecular, la activación del sistema renina-angiotensina-aldosterona (SRAA) juega un papel crucial, promoviendo vasoconstricción, retención de sodio, hipertensión intraglomerular y liberación de citoquinas profibróticas como el factor de crecimiento transformante beta (TGF- β) (Remuzzi et al., 2006). Los procesos inflamatorios crónicos están mediados por la activación de células inmunes residentes y reclutadas, que producen citoquinas proinflamatorias como IL-1, IL-6 y TNF- α . Estas citoquinas, junto con factores de crecimiento como el PDGF y el TGF- β , promueven la transdiferenciación de células tubulares epiteliales a miofibroblastos, un proceso conocido como transición epitelio-mesénquima, que contribuye significativamente a la fibrosis renal (Liu, 2011). El estrés oxidativo, caracterizado por un desequilibrio entre la producción de especies reactivas de oxígeno (ROS) y los mecanismos antioxidantes, representa otro mecanismo patogénico relevante. Los ROS causan daño directo a lípidos, proteínas y ADN celular, además de activar vías de señalización que promueven inflamación y fibrosis (Ruiz et al., 2013).

1.5 Manifestaciones Clínicas y Complicaciones

Las manifestaciones clínicas de la ERC varían según el estadio de la enfermedad, la etiología subyacente y la presencia de comorbilidades. Los estadios iniciales (G1-G3a) suelen ser asintomáticos, detectándose frecuentemente mediante hallazgos incidentales en análisis rutinarios (Webster et al., 2017). A medida que la función renal se deteriora (estadios G3b-G5), pueden aparecer síntomas inespecíficos como fatiga, anorexia, náuseas, prurito y alteraciones del sueño. Las complicaciones específicas de la ERC incluyen la anemia, principalmente debido a la disminución de la producción de eritropoyetina; alteraciones del metabolismo mineral y óseo, que conducen a la osteodistrofia renal; acidosis metabólica, resultante de la disminución en la excreción de ácidos; y desnutrición proteico-calórica, característica del síndrome de desgaste asociado a la ERC (Kazancıoğlu, 2013). Las complicaciones cardiovasculares representan la principal causa de morbilidad en pacientes con ERC. La asociación entre ERC y enfermedad cardiovascular es bidireccional: la ERC constituye un factor de riesgo independiente para eventos cardiovasculares, mientras que la enfermedad cardiovascular puede acelerar la progresión de la ERC. Los mecanismos implicados incluyen la calcificación vascular acelerada, disfunción endotelial, inflamación crónica, estrés oxidativo y activación simpática (Go et al., 2004; Sarnak et al., 2003). Las complicaciones neurológicas abarcan desde la encefalopatía urémica en estadios avanzados hasta alteraciones cognitivas sutiles en estadios tempranos. La neuropatía periférica, caracterizada por polineuropatía sensoriomotora simétrica distal, afecta hasta al 60-100Las alteraciones hidroelectrolíticas y del equilibrio ácido-base son frecuentes en la ERC avanzada e incluyen hiperpotasemia, hiponatremia, hiperosfitemia, hipocalcemia y acidosis metabólica, cada una con sus manifestaciones clínicas específicas y potenciales complicaciones (Palmer & Clegg, 2015).

1.6 Diagnóstico y Evaluación

El diagnóstico de la ERC se basa en la detección de anomalías estructurales o funcionales del riñón que persisten durante más de tres meses. La evaluación inicial debe incluir la historia clínica completa, exploración física, análisis de orina, determinaciones bioquímicas séricas y estudios de imagen (KDIGO, 2013). La TFG constituye el mejor indicador global de la función renal. Aunque la medición directa mediante aclaramiento de inulina representa el estándar de oro, en la práctica clínica se utilizan ecuaciones predictivas basadas en la creatinina sérica, como la ecuación CKD-EPI (Chronic Kidney Disease Epidemiology Collaboration), que ha demostrado mayor precisión que fórmulas previas como MDRD (Modification of Diet in Renal Disease) (Levey et al., 2009). Recientemente, biomarcadores alternativos como la cistatina C han mostrado utilidad complementaria, especialmente en poblaciones específicas como ancianos, pacientes con masa muscular reducida o con función renal entre normal y levemente reducida (Inker et al., 2012). La evaluación de la albuminuria, preferentemente mediante el cociente albúmina/creatinina en una muestra aislada de orina, constituye un indicador sensible de daño glomerular y un predictor independiente de progresión de la ERC y de eventos cardiovasculares (Hemmelgarn et al., 2010). Los estudios de imagen, particularmente la ecografía renal, permiten evaluar la morfología y tamaño renales, detectar obstrucción de la vía urinaria y valorar la presencia de lesiones quísticas o masas renales. Técnicas avanzadas como la resonancia magnética, especialmente secuencias funcionales como la difusión, elastografía o la espectroscopia, ofrecen información adicional sobre fibrosis y microestructura renal (Grenier et al., 2016). La biopsia renal permanece como el método

diagnóstico definitivo para determinar la etiología específica de muchas nefropatías, especialmente en casos de proteinuria significativa, hematuria glomerular, deterioro inexplicable de la función renal o sospecha de enfermedades sistémicas con afectación renal (Fiorentino et al., 2016).

1.7 Tratamiento y Manejo

El manejo de la ERC debe ser integral, adaptado al estadio de la enfermedad y a las comorbilidades del paciente. Los objetivos terapéuticos incluyen la ralentización de la progresión de la enfermedad, la prevención y tratamiento de complicaciones, y la preparación adecuada para la terapia renal sustitutiva cuando sea necesaria (KDIGO, 2013). Las intervenciones para retrasar la progresión de la ERC incluyen el control estricto de la presión arterial, con objetivos específicos según el perfil de riesgo del paciente y el grado de albuminuria. Los inhibidores del sistema renina-angiotensina-aldosterona, como los inhibidores de la enzima convertidora de angiotensina (IECA) y los antagonistas de los receptores de angiotensina II (ARA-II), constituyen la primera línea terapéutica por su efecto nefroprotector adicional, independiente de la reducción de la presión arterial (Ruggenenti et al., 2012). Los inhibidores del cotransportador sodio-glucosa tipo 2 (iSGLT2) y los agonistas del receptor del péptido similar al glucagón tipo 1 (arGLP-1) han emergido como opciones terapéuticas prometedoras en pacientes con ERC, especialmente aquellos con diabetes mellitus tipo 2, debido a sus efectos reno-protectores demostrados en ensayos clínicos recientes (Perkovic et al., 2019; Mann et al., 2017). El control glucémico óptimo en pacientes diabéticos es esencial para la prevención y manejo de la nefropatía diabética. La hemoglobina glicosilada objetivo debe individualizarse según la edad del paciente, comorbilidades, riesgo de hipoglucemia y expectativa de vida (Tuttle et al., 2014). Las modificaciones dietéticas incluyen la restricción proteica moderada ($0.6\text{--}0.8 \text{ g/kg/día}$), que ha demostrado ralentizar la progresión de la ERC en algunos estudios, aunque la evidencia no es concluyente. La restricción de sodio ($<2 \text{ g/día}$), la moderación en la ingesta de potasio y fósforo, y la adecuada ingesta calórica son otros aspectos dietéticos relevantes (Kalantar-Zadeh & Fouque, 2017). El manejo de las complicaciones específicas incluye la corrección de la anemia mediante agentes estimuladores de la eritropoyesis y suplementos de hierro; el tratamiento de las alteraciones del metabolismo mineral y óseo mediante quelantes del fósforo, análogos de la vitamina D y calcimiméticos; la corrección de la acidosis metabólica mediante suplementos de bicarbonato; y el manejo del prurito mediante emolientes tópicos, gabapentinoides y, en casos refractarios, antagonistas del receptor u-opioide (Palmer et al., 2013; Bover et al., 2019). La terapia renal sustitutiva, que incluye la diálisis (hemodiálisis o diálisis peritoneal) y el trasplante renal, está indicada en estadios avanzados de ERC (TFG $<15 \text{ ml/min/1.73 m}^2$) o antes si existen síntomas o complicaciones urémicas. El trasplante renal, cuando es posible, ofrece la mejor supervivencia y calidad de vida a largo plazo (Wolfe et al., 1999). Los cuidados paliativos deben integrarse precozmente en el manejo de pacientes con ERC avanzada, especialmente en aquellos con múltiples comorbilidades, edad avanzada o contraindicaciones para terapia renal sustitutiva, enfocándose en el control de síntomas y la mejora de la calidad de vida (Davison, 2011).

2. Modelos Predictivos en Salud 2.1 Fundamentos del Aprendizaje Automático en Medicina

El aprendizaje automático (Machine Learning, ML) representa un subconjunto de la inteligencia artificial que desarrolla algoritmos capaces de aprender patrones a partir de datos, sin ser explícitamente programados para tareas específicas. En el contexto médico, estos algoritmos pueden extraer relaciones complejas entre variables clínicas, genéticas, demográficas y ambientales para predecir diagnósticos, pronósticos o respuestas terapéuticas (Rajkomar et al., 2019). Los paradigmas fundamentales del aprendizaje automático incluyen el aprendizaje supervisado, donde los algoritmos aprenden a partir de ejemplos etiquetados; el aprendizaje no supervisado, que identifica patrones intrínsecos en datos no etiquetados; y el aprendizaje por refuerzo, que optimiza decisiones secuenciales a través de sistemas de recompensa (Deo, 2015). Las aplicaciones del ML en medicina abarcan desde la interpretación automatizada de imágenes diagnósticas hasta la predicción de reingresos hospitalarios, la estratificación de riesgo de enfermedades y la medicina de precisión (Beam & Kohane, 2018). La integración de estas tecnologías promete transformar el paradigma médico actual hacia un modelo predictivo, preventivo, personalizado y participativo (medicina 4P) (Hood & Friend, 2011). A pesar de su potencial, la implementación del ML en la práctica clínica enfrenta desafíos significativos, incluidos la calidad y representatividad de los datos, la reproducibilidad de los modelos, la interpretabilidad algorítmica y las consideraciones éticas y regulatorias (Shah et al., 2019).

2.2 Tipos de Algoritmos y su Aplicación en Nefrología

Diversos algoritmos de aprendizaje automático han sido aplicados en el contexto de la nefrología, cada uno con características específicas que los hacen más adecuados para determinados tipos de problemas y conjuntos de datos. Los modelos de regresión logística, aunque técnicamente no se consideran algoritmos de aprendizaje automático avanzados, representan el punto de partida para la mayoría de análisis predictivos en nefrología debido a su interpretabilidad y relativa simplicidad. Estos modelos han sido ampliamente utilizados para la predicción del riesgo de ERC en poblaciones de alto riesgo (Tangri et al., 2011). Las máquinas de vectores de soporte (Support Vector Machines, SVM) son métodos de clasificación que buscan el hiperplano que mejor separa las clases en un espacio multidimensional. En nefrología, han demostrado utilidad en la clasificación de biopsias renales a partir de imágenes microscópicas y en la predicción de la progresión de la ERC (Nelloré & Thompson, 2018). Los árboles de decisión y sus extensiones como Random Forest y Gradient Boosting representan algoritmos particularmente valiosos en el contexto clínico debido a su capacidad para manejar datos heterogéneos y su interpretabilidad relativa. Estos modelos han sido aplicados para la predicción de la progresión de la ERC, la identificación de pacientes con riesgo de lesión renal aguda y la estratificación del riesgo en pacientes con trasplante renal (Leung et al., 2013; Lee et al., 2018). Las redes neuronales artificiales, especialmente las arquitecturas profundas (Deep Learning), han revolucionado la capacidad de procesamiento de datos complejos como imágenes, señales y texto no estructurado. En nefrología, se han aplicado para la segmentación automática de riñones en imágenes radiológicas, la interpretación automatizada de biopsias renales y la predicción de la progresión de la ERC integrando múltiples fuentes de datos (Kuo et al., 2019). Los modelos bayesianos, basados en el teorema de Bayes, incorporan conocimiento previo y cuantifican explícitamente la incertidumbre en sus predicciones, características particularmente valiosas en la toma de decisiones clínicas. Estos modelos han sido utilizados para la predicción de eventos adversos en pacientes con ERC y para la personalización de regímenes de diálisis (Ibrahim et al., 2019).

2.3 Desarrollo y Validación de Modelos Predictivos

El desarrollo de modelos predictivos robustos requiere una metodología rigurosa que comprenda múltiples etapas, desde la definición del problema hasta la implementación y monitorización en entornos clínicos reales. La definición del problema clínico constituye el punto de partida, especificando claramente la población objetivo, el resultado a predecir, el horizonte temporal de la predicción y la utilidad clínica esperada del modelo. Esta fase debe involucrar a expertos clínicos para garantizar la relevancia y aplicabilidad del modelo (Steyerberg & Vergouwe, 2014). La selección y preparación de datos representa un paso crítico. Los conjuntos de datos deben ser representativos de la población objetivo y contener variables predictoras relevantes con calidad adecuada. El preprocesamiento de datos incluye la gestión de valores ausentes, la normalización de variables continuas, la codificación de variables categóricas y la detección y manejo de valores atípicos (Kuhn & Johnson, 2013). La selección de características (feature selection) busca identificar el subconjunto óptimo de variables predictoras, eliminando aquellas redundantes o irrelevantes. Este proceso mejora la generalización del modelo, reduce la dimensionalidad y facilita la interpretación. Métodos comunes incluyen enfoques basados en filtros (correlación, información mutua), enfoques basados en modelos (regularización Lasso, Ridge) y métodos de envoltura (wrapper methods) (Guyon & Elisseeff, 2003). El entrenamiento del modelo implica la optimización de hiperparámetros específicos del algoritmo seleccionado. Técnicas como la validación cruzada y la búsqueda en rejilla (grid search) permiten identificar la configuración óptima que maximiza el rendimiento sin sobreajuste (Luo et al., 2016). La evaluación del rendimiento debe realizarse en

conjuntos de datos independientes no utilizados durante el entrenamiento. Métricas comunes incluyen el área bajo la curva ROC (AUC-ROC), sensibilidad, especificidad, valor predictivo positivo y negativo, y el estadístico C (concordancia). Para modelos de regresión, se utilizan métricas como el error cuadrático medio (RMSE) y el coeficiente de determinación (R^2) (Alba et al., 2017). La calibración del modelo evalúa la concordancia entre las probabilidades predichas y las frecuencias observadas del evento. Se visualiza mediante gráficos de calibración y se cuantifica con estadísticos como la prueba de Hosmer-Lemeshow o el índice de calibración (Steyerberg et al., 2010). La validación externa en cohortes independientes, preferiblemente de diferentes instituciones o períodos temporales, resulta esencial para evaluar la generalización del modelo a nuevas poblaciones. La discriminación y calibración pueden deteriorarse significativamente en la validación externa, lo que subraya la importancia de este paso (Siontis et al., 2015). La interpretabilidad del modelo cobra especial relevancia en el contexto médico. Técnicas como SHAP (SHapley Additive exPlanations) y LIME (Local Interpretable Model-agnostic Explanations) permiten comprender las contribuciones individuales de cada variable a las predicciones específicas, facilitando la aceptación por parte de los profesionales clínicos (Lundberg & Lee, 2017). La evaluación del impacto clínico mediante estudios de implementación representa la validación definitiva de un modelo predictivo. Estos estudios evalúan si la implementación del modelo en la práctica clínica mejora los resultados de los pacientes, la eficiencia de los procesos asistenciales o la relación coste-efectividad (Moons et al., 2012).

2.4 Modelos Específicos para Predicción de ERC La literatura científica recoge numerosos modelos predictivos específicamente desarrollados para la identificación temprana de la ERC, la predicción de su progresión o la estimación del riesgo de complicaciones asociadas. El modelo de Tangri, también conocido como Kidney Failure Risk Equation (KFRE), representa uno de los modelos más validados para la predicción de la progresión a enfermedad renal terminal en pacientes con ERC. Desarrollado inicialmente en una cohorte canadiense y posteriormente validado en múltiples poblaciones internacionales, este modelo integra variables clínicas y de laboratorio fácilmente disponibles como edad, sexo, TFG estimada, albuminuria, calcio sérico, fósforo, bicarbonato y albúmina. Existen versiones de 4 y 8 variables con rendimiento similar, lo que facilita su aplicación en diferentes contextos clínicos (Tangri et al., 2011; Tangri et al., 2016). El modelo QKidney, desarrollado en el Reino Unido a partir de registros electrónicos de atención primaria, estima el riesgo de desarrollar ERC moderada-severa a 5 años en población general. Incorpora factores demográficos, comorbilidades, medicaciones y factores de riesgo modificables como tabaquismo e índice de masa corporal. Destaca por su desarrollo en una amplia muestra poblacional (más de 2.5 millones de individuos) y su integración en calculadoras clínicas de uso rutinario en atención primaria (Hippisley-Cox & Coupland, 2010). El modelo de Johns Hopkins para la identificación de ERC no diagnosticada utiliza datos administrativos y demográficos para identificar individuos con alta probabilidad de ERC no reconocida en entornos de atención primaria. Este enfoque permite la detección oportunista de casos sin necesidad de pruebas adicionales, maximizando la eficiencia del cribado (Chang et al., 2019). En el ámbito de la lesión renal aguda (LRA) como precursora de ERC, el modelo AKI to CKD integra características de episodios de LRA (duración, severidad, recurrencia) con marcadores tradicionales de riesgo renal para predecir el desarrollo posterior de ERC. Este modelo subraya la importancia del seguimiento nefrológico post-LRA (Chawla et al., 2017). Los modelos basados en aprendizaje automático avanzado para la predicción de ERC han proliferado en los últimos años. Chen et al. (2019) desarrollaron un modelo basado en redes neuronales profundas que integra datos longitudinales de historias clínicas electrónicas, demostrando superior rendimiento predictivo comparado con modelos estadísticos tradicionales. Koyner et al. (2018) aplicaron algoritmos de gradient boosting para la predicción temprana de ERC incidente a partir de datos rutinarios de laboratorio, alcanzando valores de AUC superiores a 0.90. Los modelos específicos para poblaciones especiales incluyen el modelo SCORED para población diabética, que estratifica el riesgo de ERC en pacientes con diabetes mellitus tipo 2 utilizando variables simples como edad, índice de masa corporal, antecedentes cardiovasculares y parámetros analíticos básicos (Bang et al., 2007), y el modelo CRIC para pacientes con ERC establecida, que predice la progresión de la enfermedad incorporando biomarcadores específicos de lesión tubular como KIM-1 y NGAL (Bansal et al., 2016). 2.5 Evaluación del Rendimiento y Limitaciones La evaluación rigurosa del rendimiento de los modelos predictivos resulta esencial para determinar su validez y utilidad clínica. Esta evaluación debe considerar múltiples dimensiones y reconocer las limitaciones inherentes a los datos y algoritmos utilizados. La discriminación, que evalúa la capacidad del modelo para distinguir entre individuos que experimentarán y no experimentarán el evento de interés, se cuantifica habitualmente mediante el estadístico C o área bajo la curva ROC (AUC-ROC). Valores superiores a 0.8 se consideran indicativos de buena discriminación, aunque este umbral puede variar según el contexto clínico y la prevalencia del evento (Alba et al., 2017). La calibración, que evalúa la concordancia entre las probabilidades predichas y las frecuencias observadas del evento, resulta crítica para la toma de decisiones individualizadas. Se visualiza mediante gráficos de calibración que comparan probabilidades predichas y observadas en deciles de riesgo, y se cuantifica mediante pruebas estadísticas como Hosmer-Lemeshow o índices de recalibración (Van Calster et al., 2019). La utilidad clínica trasciende medidas puramente estadísticas para evaluar el beneficio neto de utilizar el modelo en la práctica clínica. El análisis de curvas de decisión (decision curve analysis) representa una metodología clave para cuantificar este beneficio a diferentes umbrales de decisión clínica, incorporando las consecuencias relativas de falsos positivos y negativos (Vickers et al., 2016). Entre las limitaciones comunes de los modelos predictivos en nefrología destacan el sesgo de selección en las cohortes de desarrollo, particularmente la infrarrepresentación de minorías étnicas y poblaciones socioeconómicamente desfavorecidas; la variabilidad en la definición de desenlaces, especialmente relevante en ERC donde diferentes criterios de progresión dificultan la comparabilidad entre estudios; y el manejo inadecuado de datos longitudinales, que frecuentemente ignora la naturaleza dinámica de factores de riesgo y biomarcadores (He et al., 2019). El sobreajuste (overfitting) representa una limitación particularmente relevante en modelos complejos con múltiples variables predictoras y tamaños muestrales limitados. Este fenómeno conduce a excelente rendimiento en datos de entrenamiento pero pobre generalización a nuevas cohortes. Técnicas como regularización, validación cruzada y conjuntos de prueba independientes ayudan a mitigar este problema (Riley et al., 2019). La interpretabilidad limitada de modelos de caja negra como redes neuronales profundas o ensamblajes complejos dificulta su adopción en entornos clínicos donde la transparencia en la toma de decisiones resulta fundamental. Técnicas emergentes de interpretabilidad como SHAP, LIME y análisis de importancia de características intentan abordar esta limitación, aunque a menudo a expensas de la precisión o la complejidad computacional (Ahmad et al., 2018). La generalización limitada a nuevas poblaciones o entornos clínicos constituye un desafío persistente. Modelos desarrollados en poblaciones específicas pueden mostrar rendimiento subóptimo cuando se aplican a pacientes de diferentes características demográficas, con patrones de comorbilidad distintos o atendidos en sistemas sanitarios con prácticas divergentes. La transferencia de aprendizaje y la actualización adaptativa de modelos representan estrategias prometedoras para abordar esta limitación (Wiens et al., 2019). La disponibilidad y calidad de datos en tiempo real para la implementación clínica representa otro obstáculo significativo. Muchos modelos se desarrollan con datos retrospectivos cuidadosamente curados, pero deben enfrentarse en la implementación a datos incompletos, inconsistentes o registrados con diferentes estándares y definiciones (Chen & Asch, 2017).

3. Herramientas de Apoyo a la Decisión Clínica 3.1 Definición y Evolución de los Sistemas de Apoyo a la Decisión Clínica Los Sistemas de Apoyo a la Decisión Clínica (SADC) se definen como herramientas informáticas diseñadas para proporcionar a los profesionales sanitarios conocimiento e información específica, inteligentemente filtrada y presentada en momentos apropiados, para mejorar la atención al paciente (Bernier, 2007). Estos sistemas integran conocimiento médico, datos específicos del paciente y algoritmos de razonamiento para generar recomendaciones o alertas que asisten al médico en la toma de decisiones diagnósticas, terapéuticas o preventivas. La evolución histórica de los SADC refleja el desarrollo paralelo de la informática médica y la inteligencia artificial. Los primeros sistemas, desarrollados en las décadas de 1960-70, como MYCIN para enfermedades infecciosas e INTERNIST-1 para diagnóstico en medicina interna, utilizaban reglas explícitas de conocimiento médico codificadas manualmente por expertos (Shortliffe, 1976). Estos sistemas pioneros demostraron la factibilidad del

concepto, pero su aplicabilidad clínica se vio limitada por interfaces poco amigables y la dificultad para mantener actualizadas las bases de conocimiento. En las décadas de 1980-90, surgieron sistemas basados en el procesamiento del lenguaje natural y en la integración con registros médicos electrónicos, como DXplain y QMR (Quick Medical Reference). Estos sistemas mejoraron la usabilidad e incorporaron mecanismos probabilísticos para manejar la incertidumbre diagnóstica (Miller, 1994). El cambio de siglo trajo consigo la integración de los SADC con sistemas de información hospitalaria y registros electrónicos de salud, permitiendo la generación automática de alertas y recordatorios en tiempo real basados en datos específicos del paciente. Sistemas como LDS HELP y Regenstrief Medical Record System fueron pioneros en esta integración (Kawamoto et al., 2005). La era actual se caracteriza por SADC basados en aprendizaje automático, sistemas expertos híbridos y computación cognitiva. Estos sistemas modernos procesan grandes volúmenes de datos heterogéneos, incluyendo texto libre de notas clínicas, imágenes médicas y datos genómicos, para generar recomendaciones cada vez más personalizadas y contextualizadas. Ejemplos notables incluyen IBM Watson Health y sistemas desarrollados por empresas emergentes de salud digital (Shortliffe & Sepúlveda, 2018).

3.2 Taxonomía y Componentes de los SADC Los SADC pueden clasificarse según múltiples dimensiones, incluyendo su arquitectura técnica, funcionalidad clínica, modelo de conocimiento subyacente y modalidad de interacción con el usuario (Wright et al., 2011). Según su arquitectura técnica, pueden distinguirse SADC independientes, que funcionan como aplicaciones autónomas; SADC integrados en sistemas de información clínica, que se incorporan directamente en el flujo de trabajo del registro electrónico; y SADC basados en servicios, que utilizan arquitecturas orientadas a servicios para proporcionar funcionalidades a través de interfaces de programación de aplicaciones (APIs) (Osheroff et al., 2012). Según su funcionalidad clínica, los SADC pueden clasificarse como sistemas de documentación, que facilitan la entrada estructurada de datos clínicos; sistemas de acceso a conocimiento, que proporcionan información relevante bajo demanda; sistemas de gestión de alertas, que presentan avisos y recordatorios en momentos específicos; sistemas de apoyo diagnóstico, que asisten en la identificación de enfermedades; sistemas de dosificación, que recomiendan ajustes de medicación; y sistemas predictivos, que estiman riesgos futuros para la planificación preventiva (Musen et al., 2014). Según el modelo de conocimiento subyacente, pueden distinguirse SADC basados en reglas lógicas, que utilizan condicionales si-entonces para codificar conocimiento médico explícito; sistemas probabilísticos, que incorporan incertidumbre mediante redes bayesianas o modelos estadísticos; sistemas basados en casos, que utilizan razonamiento analógico con casos previos similares; y sistemas híbridos, que combinan múltiples aproximaciones (Castaneda et al., 2015). Los componentes fundamentales de un SADC moderno incluyen: 1. Base de conocimiento: Repositorio estructurado de información médica, que puede incluir reglas de decisión, modelos estadísticos, literatura médica indexada o casos previos. Esta base requiere actualización periódica para incorporar nueva evidencia científica (Bernier, 2007). 2. Motor de inferencia: Mecanismo que procesa la información específica del paciente en el contexto de la base de conocimiento para generar conclusiones relevantes. Puede utilizar diferentes paradigmas como lógica deductiva, razonamiento probabilístico o algoritmos de aprendizaje automático (Kong et al., 2008). 3. Mecanismo de comunicación: Interfaz que presenta las recomendaciones al usuario de manera comprensible y accionable, y potencialmente recibe retroalimentación para refinar futuras sugerencias. Incluye aspectos de visualización de datos, diseño de alertas y personalización de la presentación (Kawamoto et al., 2005). 4. Modelo de adquisición de datos: Componente que obtiene, valida e integra información específica del paciente de múltiples fuentes, incluyendo registros electrónicos, dispositivos médicos y entrada directa del usuario (Wright et al., 2015). 5. Mecanismo de explicación: Funcionalidad que proporciona justificación para las recomendaciones generadas, permitiendo al usuario comprender el razonamiento subyacente y evaluar su aplicabilidad al caso específico (Shortliffe & Sepúlveda, 2018).

3.3 Diseño e Implementación de SADC Efectivos El diseño e implementación de SADC efectivos requiere un enfoque multidisciplinar que integre consideraciones clínicas, técnicas, organizativas y humanas. La literatura ha identificado factores críticos que influyen en el éxito y adopción de estos sistemas (Kawamoto et al., 2005; Bates et al., 2003). La provisión automática de apoyo como parte del flujo de trabajo clínico habitual, sin requerir activación específica por parte del usuario, constituye uno de los predictores más robustos de efectividad. Los sistemas que requieren búsqueda activa o navegación adicional presentan tasas de utilización significativamente inferiores (Kawamoto et al., 2005). La generación de recomendaciones específicas y accionables, en lugar de mera valoración de situaciones, mejora la utilidad percibida y la adherencia a las sugerencias. Las recomendaciones deben ser concretas, factibles en el contexto clínico actual y formuladas en lenguaje orientado a la acción (Bates et al., 2003). La presentación de información en el momento y lugar de la toma de decisiones, conocido como "Apoyo en el punto de atención", maximiza la relevancia y aplicabilidad de las recomendaciones. Los sistemas que proporcionan información retrospectivamente o requieren consulta en ubicaciones separadas muestran menor impacto en la práctica clínica (Sittig et al., 2008). El diseño centrado en el usuario, que incorpora principios de usabilidad y comprende el contexto real de trabajo clínico, resulta fundamental para la aceptación del sistema. La participación de usuarios finales durante todo el ciclo de desarrollo permite identificar barreras potenciales y adaptar la interfaz a las necesidades reales (Johnson et al., 2011). La transparencia en el razonamiento y la capacidad de proporcionar justificación para las recomendaciones aumentan la confianza de los profesionales y facilitan la evaluación contextual de su aplicabilidad. Los SADC percibidos como "cajas negras" generan resistencia, especialmente entre especialistas con experiencia (Shortliffe & Sepúlveda, 2018). La integración con sistemas existentes y la interoperabilidad con el ecosistema de información sanitaria constituyen requisitos prácticos para la implementación sostenible. Los SADC que requieren doble entrada de datos o consulta de múltiples sistemas generan carga cognitiva adicional y dificultades en el flujo de trabajo (Wright et al., 2015). La gestión adecuada de alertas, evitando la fatiga por exceso de notificaciones, representa un aspecto crítico del diseño. El equilibrio entre sensibilidad y especificidad, la priorización basada en gravedad y la personalización de umbrales según preferencias del usuario y contexto clínico pueden mitigar este problema (van der Sijs et al., 2006). La evaluación continua y mejora iterativa, basada en métricas de proceso y resultado, aseguran la relevancia clínica sostenida del sistema. Los SADC deben incorporar mecanismos para monitorizar su utilización, adherencia a recomendaciones e impacto en resultados clínicos (Osheroff et al., 2012).

3.4 SADC en Nefrología y ERC La aplicación de SADC en el ámbito específico de la nefrología y la ERC ha experimentado un desarrollo creciente en las últimas décadas, abordando múltiples aspectos del diagnóstico, estadificación, monitorización, prevención y tratamiento de la enfermedad renal. Los sistemas para la detección y estadificación automática de la ERC representan una de las aplicaciones más extendidas. Estos sistemas analizan valores de creatinina sérica y albuminuria de registros electrónicos para identificar pacientes que cumplen criterios de ERC, calcular la TFG estimada mediante fórmulas validadas y clasificar según las categorías KDIGO. Estudios han demostrado que estos sistemas mejoran significativamente la documentación de ERC y la adherencia a guías de cuidado recomendadas (Drawwz et al., 2015). Los SADC para la prevención de nefrototoxicidad inducida por medicamentos o medios de contraste integran información sobre función renal, medicación concurrente y factores de riesgo para generar alertas de ajuste de dosis, contraindicaciones o recomendaciones de hidratación profiláctica. Sistemas como el desarrollado por Nash et al. (2005) demostraron reducciones significativas en la incidencia de lesión renal aguda asociada a nefrotóxicos en entornos hospitalarios. Las herramientas de predicción de riesgo integradas en flujos clínicos implementan modelos como la Kidney Failure Risk Equation de Tangri directamente en registros electrónicos, permitiendo la estratificación automática de pacientes según su riesgo de progresión a enfermedad renal terminal. Estas implementaciones han demostrado mejorar la adecuación y oportunidad de derivaciones a nefrología y la planificación de acceso vascular para diálisis (Drawwz et al., 2016). Los sistemas de apoyo para el manejo de complicaciones específicas de la ERC incluyen herramientas para el ajuste de medicación antihipertensiva según objetivos individualizados, calculadoras de riesgo cardio-renal, alertas de valores críticos de potasio o fósforo, y recomendaciones para el manejo de la anemia asociada a ERC. El sistema CDSS-CKD desarrollado por Samal et al. (2014) integra múltiples módulos para abordar complicaciones específicas, mostrando mejoras en adherencia a guías clínicas y reducción de hospitalizaciones. Los SADC para optimización de diálisis incluyen sistemas que analizan parámetros

de adecuación dialítica, balance hídrico y respuesta a medicación para sugerir ajustes en prescripciones de hemodiálisis o diálisis peritoneal. Sistemas como TDSS (Teruel Dialysis Support System) utilizan modelado matemático para personalizar esquemas de ultrafiltración y concentración de electrolitos en el dializado, mostrando mejoras en la estabilidad hemodinámica durante las sesiones (Sánchez-de la Torre et al., 2020). Las herramientas de telemonitorización para ERC avanzada combinan dispositivos remotos de medición (tensiómetros, básculas, glucómetros) con algoritmos de análisis para detectar precozmente descompensaciones y prevenir hospitalizaciones. Sistemas como IRAC (Insuficiencia Renal Avanzada Controlada) han demostrado reducciones significativas en ingresos hospitalarios y visitas a urgencias en pacientes con ERC estadios 4-5 no dialíticos (Gallar et al., 2007). 3.5 Evaluación de Impacto y Barreras para la Implementación La evaluación rigurosa del impacto de los SADC en la práctica clínica real constituye un aspecto fundamental para justificar su implementación y orientar su mejora continua. Esta evaluación debe considerar múltiples dimensiones y utilizar metodologías apropiadas para capturar tanto efectos directos como indirectos (Bright et al., 2012). Los dominios de evaluación incluyen medidas de proceso, como la adherencia a guías clínicas, la realización de pruebas diagnósticas apropiadas o la prescripción de medicación recomendada; medidas de resultado intermedio, como el control de presión arterial, niveles de HbA1c o progresión de la TFG; y medidas de resultado final, como mortalidad, eventos cardiovasculares, progresión a terapia renal sustitutiva o calidad de vida relacionada con la salud (Roshanov et al., 2013). La evidencia acumulada sobre la efectividad de los SADC muestra resultados heterogéneos. Una revisión sistemática de Bright et al. (2012) que incluyó 148 ensayos controlados aleatorizados encontró que los SADC mejoraban significativamente medidas de proceso en aproximadamente el 60% en el ámbito específico de la nefrología, los estudios controlados son limitados, pero sugieren beneficios principalmente en detección temprana de ERC, prevención de nefrotoxicidad y adherencia a monitorización recomendada. El efecto sobre resultados como progresión de la ERC o mortalidad permanece insuficientemente demostrado, en parte debido a la naturaleza crónica de la enfermedad que requiere seguimientos prolongados para detectar diferencias significativas (Barbour et al., 2016). Las barreras para la implementación exitosa de SADC en nefrología incluyen factores técnicos, organizativos, profesionales y relacionados con los pacientes. Entre los factores técnicos destacan la fragmentación de sistemas de información clínica, la escasa interoperabilidad entre plataformas y la calidad variable de los datos disponibles en tiempo real (Bates et al., 2018). Los factores organizativos incluyen las limitaciones de recursos para la adquisición e implementación de nuevas tecnologías, la ausencia de estrategias de cambio organizacional que acompañen la introducción de SADC y la falta de alineamiento con prioridades institucionales (Ross et al., 2016). Las barreras relacionadas con los profesionales comprenden la resistencia al cambio en rutinas establecidas, la percepción de amenaza a la autonomía clínica, la desconfianza en algoritmos automatizados y la preocupación por responsabilidad legal asociada a recomendaciones algorítmicas (Khairat et al., 2018). Entre los factores relacionados con los pacientes destacan las preocupaciones sobre privacidad y confidencialidad de datos clínicos, la preferencia por la toma de decisiones exclusivamente humana en cuestiones de salud y las disparidades en alfabetización digital que podrían exacerbar inequidades existentes (Peek et al., 2014). Las estrategias para superar estas barreras incluyen el diseño participativo que involucra a todos los actores relevantes desde las fases iniciales; la implementación gradual con períodos de adaptación y retroalimentación; la capacitación específica sobre uso e interpretación de recomendaciones algorítmicas; la transparencia sobre fuentes de datos y lógica decisional; y la evaluación continua con métricas significativas para los usuarios finales (Sittig et al., 2008). 4. Integración de Modelos Predictivos en la Práctica Clínica Nefrológica 4.1 Del Modelo al Impacto Clínico: Marco Conceptual La traslación efectiva de modelos predictivos a la práctica clínica requiere un marco conceptual que contemple las múltiples dimensiones del proceso, desde el desarrollo técnico del algoritmo hasta su impacto en resultados de salud. Diversos autores han propuesto marcos que estructuran esta traslación en fases secuenciales pero interrelacionadas (Shah et al., 2019; Wiens et al., 2019). El continuo investigación-implementación puede conceptualizarse en cinco fases principales: (1) desarrollo técnico y validación del modelo; (2) validación clínica en entornos reales; (3) implementación piloto en flujos de trabajo específicos; (4) implementación a escala y evaluación de impacto; y (5) monitorización continua y actualización adaptativa (Sendak et al., 2020). La perspectiva sociotécnica reconoce que la implementación exitosa depende no solo de la calidad del modelo, sino de la adecuada interacción entre tecnología, procesos organizativos, normativas institucionales y factores humanos. Este enfoque enfatiza la importancia de considerar cómo la tecnología se integra en sistemas complejos adaptativos como las organizaciones sanitarias (Sittig & Singh, 2010). La evaluación del valor añadido debe considerar múltiples perspectivas: la perspectiva clínica, centrada en la mejora de decisiones diagnósticas o terapéuticas; la perspectiva del paciente, que valora resultados relevantes como supervivencia, funcionalidad o calidad de vida; la perspectiva organizativa, que considera eficiencia, coste-efectividad y alineamiento con prioridades estratégicas; y la perspectiva poblacional, que evalúa el impacto en salud pública y equidad (Porter, 2010). El marco RE-AIM (Reach, Effectiveness, Adoption, Implementation, Maintenance) proporciona una estructura útil para evaluar sistemáticamente el impacto de innovaciones en salud, incluidos los modelos predictivos integrados en la práctica clínica. Este marco evalúa el alcance de la intervención en la población objetivo, su efectividad en condiciones reales, su adopción por profesionales e instituciones, la fidelidad y costes de implementación, y su sostenibilidad a largo plazo (Glasgow et al., 2019). 4.2 Flujos de Trabajo Clínicos y Puntos de Integración La identificación de puntos óptimos de integración dentro de flujos de trabajo clínicos existentes representa un factor crítico para la utilidad y adopción de modelos predictivos en nefrología. Estos puntos deben seleccionarse considerando momentos decisionales clave donde la información predictiva puede modificar acciones clínicas concretas (Kawamoto et al., 2005). En el contexto de la atención primaria, puntos de integración relevantes incluyen la consulta periódica de pacientes con factores de riesgo para ERC (hipertensión, diabetes), donde modelos de cribado pueden identificar candidatos para pruebas diagnósticas adicionales; la revisión de resultados analíticos, donde calculadoras automáticas pueden estimar TFG, detectar deterioro significativo y estratificar riesgo; y la planificación de seguimiento, donde predicciones de progresión pueden orientar la frecuencia e intensidad de monitorización (Stevens et al., 2017). En consultas especializadas de nefrología, puntos de integración valiosos comprenden la evaluación inicial, donde modelos comprensivos pueden estratificar pacientes según riesgo de progresión y orientar la intensidad de intervenciones; la titulación de medicación renoprotectora, donde predicciones personalizadas de beneficio-riesgo pueden informar decisiones sobre dosificación de IECA/ARA-II o introducción de nuevas terapias como iSGLT2; y la planificación de terapia renal sustitutiva, donde modelos predictivos pueden identificar pacientes con alta probabilidad de progresión a ERC terminal en plazos específicos, facilitando la preparación oportuna (Tangri et al., 2021). En entornos hospitalarios, la integración en sistemas de historia clínica electrónica puede facilitar la identificación automática de pacientes con ERC no reconocida previamente; la detección temprana de lesión renal aguda sobreañadida; la evaluación de riesgo de nefrotoxicidad ante procedimientos con contraste o prescripción de medicamentos potencialmente nefrotóxicos; y la planificación de transiciones asistenciales con recomendaciones específicas para seguimiento post-alta (Wilson et al., 2019). La integración en herramientas de te-

lemedicina y monitorización remota representa un área emergente, permitiendo la incorporación de datos fisiológicos ambulatorios (presión arterial domiciliar, peso, adherencia medicamentosa) en modelos predictivos dinámicos que pueden generar alertas tempranas de descompensación y recomendaciones de ajuste terapéutico sin necesidad de visitas presenciales (Gallar et al., 2007). 4.3 Experiencia del Usuario y Diseño de Interfaces El diseño cuidadoso de interfaces de usuario representa un componente fundamental para la adopción y utilidad de modelos predictivos en la práctica clínica. Estas interfaces deben equilibrar múltiples objetivos, a menudo contrapuestos, como comprensibilidad, eficiencia cognitiva, precisión informativa y facilidad de uso (Khairat et al., 2018). Los principios generales de diseño incluyen la simplicidad visual, evitando la sobrecarga cognitiva mediante la presentación selectiva de información crítica; la consistencia en terminología, códigos cromáticos y estructuras navegacionales; la transparencia sobre fuentes de datos, limitaciones predictivas y grados de incertidumbre; y la accionabilidad, vinculando predicciones con opciones concretas de manejo (Horsky et al., 2012). La visualización efectiva de predicciones de riesgo constituye un desafío particular. Estudios sugieren que la combinación de representaciones numéricas precisas (porcentajes, cocientes de riesgo) con visualizaciones intuitivas (gráficos de barras, escalas cromáticas, pictogramas) facilita la comprensión por parte de profesionales con diferentes perfiles. La contextualización del riesgo individual mediante comparación con población de referencia o umbrales de decisión clínica mejora la interpretabilidad y relevancia práctica (Ancker et al., 2011). La personalización de interfaces según roles profesionales y contextos asistenciales aumenta la relevancia percibida y minimiza la información redundante o irrelevante. Un nefrólogo puede requerir detalles técnicos sobre variables incluidas en el modelo y análisis de sensibilidad de la predicción, mientras que un médico de atención primaria podría beneficiarse más de recomendaciones accionables específicas derivadas de la predicción (Sittig et al., 2008). La integración fluida con flujos de documentación y ordenación clínica minimiza la carga operativa adicional. Las interfaces que requieren navegación separada, autenticación adicional o doble entrada de datos encuentran resistencia significativa independientemente de su valor predictivo. La incorporación de funcionalidades "one-click" para implementar recomendaciones derivadas de predicciones facilita la transición de conocimiento a acción (Bates et al., 2003). El diseño participativo, que involucra a usuarios finales en todas las fases del desarrollo, permite identificar preocupaciones específicas, preferencias informativas y restricciones operativas que condicionan la adopción. Técnicas como entrevistas contextuales, observación etnográfica, pruebas de usabilidad iterativas y análisis de tareas cognitivas proporcionan insights valiosos para optimizar la experiencia del usuario (Johnson et al., 2011). 4.4 Consideraciones Éticas y Regulatorias La implementación de modelos predictivos en la práctica clínica conlleva importantes consideraciones éticas y regulatorias que deben abordarse proactivamente para asegurar una innovación responsable y centrada en el paciente (Char et al., 2018). La transparencia algorítmica constituye un requerimiento ético fundamental, especialmente en decisiones de alto impacto. Esta transparencia abarca la divulgación de variables utilizadas, su ponderación relativa, la representatividad de datos de entrenamiento y las limitaciones conocidas del modelo. El nivel óptimo de transparencia debe equilibrar la comprensibilidad para usuarios no técnicos con la precisión necesaria para una evaluación informada (Wachter et al., 2017). La equidad y no discriminación representan consideraciones prioritarias, dada la documentada presencia de sesgos en datos sanitarios históricos que pueden perpetuarse o amplificarse mediante algoritmos predictivos. La evaluación sistemática de equidad, comparando rendimiento predictivo entre subgrupos demográficos y socioeconómicos, y la mitigación activa de disparidades identificadas mediante técnicas de "fairness-aware machine learning" constituyen responsabilidades éticas ineludibles (Obermeyer et al., 2019). La privacidad y seguridad de datos utilizados para entrenamiento, validación e inferencia deben garantizarse mediante protocolos robustos de anonimización, encriptación y control de acceso. La implementación de tecnologías como el aprendizaje federado, que permite entrenar modelos sin centralizar datos sensibles, representa una estrategia prometedora para equilibrar utilidad predictiva con protección de privacidad (Rieke et al., 2020). La autonomía profesional y la responsabilidad compartida plantean interrogantes sobre el rol apropiado de recomendaciones algorítmicas en la toma de decisiones clínicas. El espectro va desde modelos puramente informativos que complementan el juicio clínico hasta sistemas semiautomatizados con capacidad ejecutiva condicionada. La clarificación de responsabilidades legales y éticas ante eventos adversos relacionados con predicciones algorítmicas permanece como un área de desarrollo activo (Goodman, 2016). El marco regulatorio aplicable varía significativamente entre jurisdicciones, pero generalmente incluye normativas sobre productos sanitarios, protección de datos personales y responsabilidad profesional. En Estados Unidos, la FDA ha desarrollado marcos específicos para software como dispositivo médico (SaMD) que estratifican requisitos regulatorios según nivel de riesgo y autonomía decisional. En Europa, el Reglamento General de Protección de Datos (GDPR) establece restricciones específicas sobre decisiones automatizadas que afectan significativamente a individuos (FDA, 2019; Kaminski, 2019). La gobernanza institucional para la implementación de modelos predictivos debe incluir comités multidisciplinarios que integren perspectivas clínicas, técnicas, éticas y administrativas. Estos comités deben establecer protocolos para la evaluación previa a la implementación, monitorización continua de rendimiento e impactos no anticipados, y mecanismos de auditoría periódica (Sendak et al., 2020). 5. Estado Actual y Perspectivas Futuras en la Predicción y Manejo de la ERC 5.1 Tendencias Innovadoras en Modelado Predictivo El campo del modelado predictivo en ERC experimenta una rápida evolución impulsada por avances metodológicos, nuevas fuentes de datos y paradigmas analíticos emergentes. Estas innovaciones prometen mejorar la precisión, personalización y aplicabilidad clínica de las predicciones (Goldstein et al., 2017). Los modelos dinámicos longitudinales representan una evolución significativa respecto a modelos estáticos tradicionales. Estos enfoques, como modelos joint, modelos landmarking y redes recurrentes, incorporan la trayectoria temporal de parámetros clínicos y biomarcadores, capturando patrones de variabilidad, tendencias y respuestas a intervenciones que contienen información pronóstica valiosa. En nefrología, estos modelos han demostrado superior capacidad para predecir trayectorias individualizadas de función renal y momentos óptimos para iniciar preparación de terapia renal sustitutiva (Weldegiorgis & Woodward, 2020). La integración multimodal de datos heterogéneos constituye otra tendencia prominente. Modelos avanzados combinan datos clínicos estructurados con información genómica, datos de imagen médica, texto libre de notas clínicas y datos de sensores wearables. Arquitecturas como redes neuronales profundas con múltiples entradas especializadas permiten procesar simultáneamente estas diversas modalidades, identificando interacciones complejas inaccesibles para métodos convencionales. En ERC, estos enfoques han integrado características histológicas cuantitativas de biopsias renales con perfiles transcriptómicos y datos clínicos para predecir respuesta a tratamientos específicos en glomerulopatías (Hermesen et al., 2019). El aprendizaje por transferencia y los métodos multitarea abordan la limitación frecuente de cohortes nefrológicas relativamente pequeñas. Estas técnicas permiten aprovechar conocimiento derivado de dominios relacionados o tareas predictivas similares, mejorando el rendimiento en poblaciones con datos limitados. En ERC, modelos preentrenados con datos de múltiples sistemas hospitalarios y posteriormente "fine-tuned" en poblaciones específicas han mostrado rendimiento superior a modelos desarrollados exclusivamente con datos locales (

6.7. Anexo 7: Resultado ChatGPT tercer tema

Eres un analista de datos que tiene experiencia en análisis de datos y en investigaciones académicas. Tienes un fuerte background de medicina. Tienes una base de datos sobre la enfermedad renal crónica, estos datos tienen un número de atributos y una clasificación. Según estos datos, quieres hacer una investigación para una tesis de maestría, que tiene dos fines, uno utilizar un modelo para predecir la enfermedad, y otro hacer una herramienta para que los doctores lo utilicen de manera que ellos puedan predecir enfermedad renal crónica. Tu objetivo es plantear una selección de la metodología, intenta plantearla de forma que sea lo que se va a presentar en el documento final. Asegúrate que solo sea el objetivo que te plantee. Por favor, quiero que hagas uso del internet, y me ayudes citando cualquier dato que necesites, necesito que estén citadas en apa. Dame también después de que termines las citas en bibtex. Asegurate que las citas en bibtex solo esten al final

A continuación, se presenta la selección metodológica propuesta para la tesis de maestría enfocada en la predicción de la enfermedad renal crónica (ERC) mediante modelos de aprendizaje automático y el desarrollo de una herramienta clínica para su detección temprana.

Metodología

1. Diseño del Estudio

Se llevará a cabo un estudio cuantitativo, observacional y retrospectivo, utilizando una base de datos clínica anonimizada de pacientes con y sin diagnóstico de ERC. El objetivo es desarrollar un modelo predictivo que permita identificar la presencia de ERC y su progresión, así como diseñar una herramienta de apoyo para profesionales de la salud.



2. Preparación de los Datos

2.1. Recolección y Comprensión de los Datos

Se utilizará una base de datos que contenga variables clínicas relevantes, como edad, sexo, antecedentes médicos, resultados de laboratorio (creatinina, tasa de filtración glomerular, proteinuria, entre otros) y diagnósticos previos. Es fundamental comprender la naturaleza de cada variable y su relación con la ERC.

2.2. Preprocesamiento de Datos

El preprocesamiento incluirá:

- **Limpieza de datos:** eliminación de duplicados, corrección de errores y manejo de valores atípicos.
- **Imputación de valores faltantes:** se aplicarán técnicas como la imputación por la media, mediana o mediante algoritmos más sofisticados como K-Nearest Neighbors (KNN) o modelos de regresión, según la naturaleza de los datos faltantes.
- **Codificación de variables categóricas:** transformación de variables categóricas en variables numéricas mediante técnicas como One-Hot Encoding o Label Encoding.
- **Normalización o estandarización:** se aplicarán técnicas de escalado para asegurar que todas las variables numéricas estén en la misma escala, facilitando el entrenamiento de los modelos.

3. Selección de Características

Se emplearán métodos de selección de características para identificar las variables más relevantes en la predicción de la ERC. Entre las técnicas a utilizar se incluyen:

- **Análisis de correlación:** para identificar relaciones lineales entre variables.
- **Métodos basados en modelos:** como la importancia de características en modelos de árboles de decisión o Random Forest.
- **Eliminación recursiva de características (RFE):** para seleccionar un subconjunto óptimo de variables.

4. Desarrollo del Modelo Predictivo

Se explorarán diversos algoritmos de aprendizaje automático supervisado, incluyendo:

- **Árboles de decisión y Random Forest:** por su capacidad para manejar datos no lineales y su interpretabilidad.
- **Support Vector Machines (SVM):** efectivos en espacios de alta dimensión.
- **Redes neuronales artificiales:** para capturar relaciones complejas entre variables.

- **Árboles de decisión y Random Forest:** por su capacidad para manejar datos no lineales y su interpretabilidad.
- **Support Vector Machines (SVM):** efectivos en espacios de alta dimensión.
- **Redes neuronales artificiales:** para capturar relaciones complejas entre variables.
- **Gradient Boosting Machines (GBM):** como XGBoost o LightGBM, conocidos por su alta precisión en tareas de clasificación.

Se dividirá el conjunto de datos en conjuntos de entrenamiento y prueba, utilizando validación cruzada para evaluar el rendimiento de los modelos y evitar el sobreajuste.

5. Evaluación del Modelo

La evaluación del rendimiento de los modelos se realizará mediante métricas como:

- **Precisión, sensibilidad y especificidad:** para evaluar la capacidad del modelo en la clasificación correcta de casos positivos y negativos.
- **Área bajo la curva ROC (AUC-ROC):** para medir la capacidad del modelo en distinguir entre clases.
- **Matriz de confusión:** para analizar los errores de clasificación.

6. Desarrollo de la Herramienta Clínica

Con base en el modelo predictivo seleccionado, se desarrollará una herramienta informática (aplicación web o software de escritorio) que permita a los profesionales de la salud ingresar datos clínicos de pacientes y obtener una predicción sobre la presencia o riesgo de progresión de la ERC. La herramienta incluirá:

- **Interfaz amigable:** para facilitar su uso en entornos clínicos.
- **Visualización de resultados:** presentación clara de la predicción y factores de riesgo asociados.
- **Explicabilidad del modelo:** implementación de técnicas como SHAP (SHapley Additive exPlanations) para proporcionar interpretaciones sobre cómo cada variable influye en la predicción.

7. Validación de la Herramienta

La herramienta será validada mediante pruebas con profesionales de la salud, quienes evaluarán su utilidad, precisión y facilidad de uso. Se recopilarán retroalimentaciones para realizar mejoras iterativas en el diseño y funcionalidad de la herramienta.

Citas encontradas por ChatGPT

- Amador Martínez, W. D. (2020). Modelos de aprendizaje automático para la predicción de la progresión de la enfermedad renal crónica. Pontificia Universidad Javeriana. Recuperado de <https://repositorioslatinoamericanos.uchile.cl/handle/2250/6652473> repositorioslatinoamericanos.uchile.cl
- Rodríguez, J. (2019). Implementación de modelos de aprendizaje automático para la predicción de la enfermedad renal crónica. Universidad de Bogotá Jorge Tadeo Lozano. Recuperado de <https://expeditiorepositorio.utadeo.edu.co/handle/20.500.12010/17638> Expedito Repositorio
- Li, Z., Liu, X., Tang, Z., Zhang, P., Jin, N., Eadon, M., ... & Su, J. (2024). TrajVis: a visual clinical decision support system to translate artificial intelligence trajectory models in the precision management of chronic kidney disease. arXiv preprint arXiv:2401.08067. <https://arxiv.org/abs/2401.08067> arxiv.org
- Jawad, K. M. T., Verma, A., Amsaad, F., & Ashraf, L. (2024). AI-Driven Predictive Analytics Approach for Early Prognosis of Chronic Kidney Disease Using Ensemble Learning and Explainable AI. arXiv preprint arXiv:2406.06728. <https://arxiv.org/abs/2406.06728> arxiv.org
- Ma, J., Wang, J., Lu, L., Sun, Y., Feng, M., Shen, P., ... & Zhang, L. (2025). Development and Validation of a Dynamic Kidney Failure Prediction Model based on Deep Learning: A Real-World Study with External Validation. arXiv preprint arXiv:2501.16388. <https://arxiv.org/abs/2501.16388> arxiv.org

6.8. Anexo 8: Resultado Gemini tercer tema

Eres un analista de datos que tiene experiencia en análisis

Show thinking

Metodología

La presente investigación se enmarca dentro de un diseño de estudio observacional, retrospectivo y analítico, con un enfoque mixto que combina la ciencia de datos (análisis predictivo mediante aprendizaje automático) y la ingeniería de software (desarrollo de una herramienta de apoyo a la decisión clínica). El estudio tiene como finalidad el desarrollo y validación de un modelo predictivo para la enfermedad renal crónica (ERC) y la posterior implementación de una herramienta informática para su uso por profesionales de la salud.

1. Fuente y Recolección de Datos

La base de datos utilizada para esta investigación proviene de una fuente previamente recopilada y anonimizada, conteniendo un número de atributos clínicos y demográficos relevantes para la predicción de la ERC, así como una clasificación dicotómica que indica la presencia o ausencia de la enfermedad. Se asegurará que la base de datos cumple con todas las normativas de privacidad y protección de datos personales (RGPD, HIPAA, según corresponda a la fuente original), garantizando la confidencialidad de la información de los pacientes.

Antes del análisis, se realizará un proceso exhaustivo de preprocesamiento de datos, que incluirá:

- **Limpieza de Datos:** Identificación y tratamiento de valores atípicos (outliers) y datos faltantes (missing values). Se evaluarán métodos como la imputación de valores por la media, mediana, moda o técnicas más avanzadas como la imputación por k-vecinos más cercanos (KNN Imputer), basándose en la naturaleza de los datos y la distribución de las variables (García & Romero, 2018).

- **Limpieza de Datos:** Identificación y tratamiento de valores atípicos (outliers) y datos faltantes (missing values). Se evaluarán métodos como la imputación de valores por la media, mediana, moda o técnicas más avanzadas como la imputación por k-vecinos más cercanos (KNN Imputer), basándose en la naturaleza de los datos y la distribución de las variables (García & Romero, 2018).

- **Transformación de Datos:** Normalización o estandarización de variables numéricas para garantizar que todas las características contribuyan equitativamente al modelo, especialmente para algoritmos sensibles a la escala de los datos (e.g., SVM, redes neuronales). Las variables categóricas se codificarán utilizando técnicas como *One-Hot Encoding* (Kuhn & Johnson, 2013).

- **Exploración de Datos:** Se realizará un análisis exploratorio de datos (EDA) para comprender la distribución de las variables, identificar correlaciones entre ellas y visualizar la relación entre los atributos y la clasificación de la ERC. Esto incluirá estadísticas descriptivas, histogramas, diagramas de dispersión y matrices de correlación.

2. Variables del Estudio

- **Variable Dependiente (Variable Objetivo):**
 - Clasificación de ERC (binaria: presente/ausente).
- **Variables Independientes (Atributos Predictivos):**
 - Estas incluirán una serie de características clínicas y demográficas presentes en la base de datos, tales como: edad, sexo, presión arterial sistólica y diastólica, niveles de glucosa, urea, creatinina sérica, albúmina sérica, sodio, potasio, hemoglobina, recuento de glóbulos blancos y rojos, niveles de colesterol y triglicéridos, historial de diabetes, hipertensión, entre otros disponibles en la base de datos. La selección final de los atributos se basará en el EDA y técnicas de selección de características.

3. Desarrollo y Validación del Modelo Predictivo

El desarrollo del modelo predictivo se basará en algoritmos de aprendizaje automático, siguiendo las siguientes fases:

3.1. División de Datos

El conjunto de datos preprocesado se dividirá en tres subconjuntos:

- **Conjunto de Entrenamiento (70%):** Utilizado para ajustar los parámetros de los modelos.
- **Conjunto de Validación (15%):** Utilizado para ajustar los hiperparámetros y seleccionar el mejor modelo.
- **Conjunto de Prueba (15%):** Utilizado para evaluar el rendimiento final del modelo seleccionado en datos no vistos. Se garantizará que la división preserve la proporción de la clase objetivo (ERC presente/ausente) para evitar desequilibrios en los subconjuntos.

3.2. Selección y Adaptación de Algoritmos de Aprendizaje Automático

Se explorarán y compararán diversos algoritmos de clasificación, incluyendo, pero no limitándose a:

- **Regresión Logística:** Como modelo de línea base por su interpretabilidad y eficiencia (Hosmer et al., 2013).
- **Máquinas de Vectores de Soporte (SVM):** Adecuadas para la clasificación con alta dimensionalidad y datos no linealmente separables (Cortes & Vapnik, 1995).
- **Árboles de Decisión y Bosques Aleatorios (Random Forests):** Por su capacidad para manejar relaciones no lineales y su robustez ante el sobreajuste (Breiman, 2001).
- **Gradient Boosting (e.g., XGBoost, LightGBM):** Algoritmos de alto rendimiento que han demostrado ser efectivos en una amplia gama de problemas de clasificación (Chen & Guestrin, 2016).
- **Redes Neuronales (Perceptrón Multicapa):** Para explorar patrones complejos y no lineales en los datos (Goodfellow et al., 2016).

Se realizará una optimización de hiperparámetros para cada algoritmo utilizando técnicas como *Grid Search* o *Random Search* combinadas con validación cruzada (e.g., k-fold cross-validation) en el conjunto de entrenamiento para encontrar la configuración óptima que maximice el rendimiento del modelo (James et al., 2013).

3.3. Evaluación del Rendimiento del Modelo

El rendimiento de los modelos se evaluará utilizando un conjunto de métricas robustas para problemas de clasificación binaria, con un enfoque particular en el equilibrio entre sensibilidad y especificidad, dada la importancia del diagnóstico precoz de la ERC. Las métricas clave incluirán:

- **Precisión (Accuracy):** Proporción de predicciones correctas.
- **Sensibilidad (Recall o Tasa de Verdaderos Positivos):** Capacidad del modelo para identificar correctamente a los pacientes con ERC.
- **Especificidad (Tasa de Verdaderos Negativos):** Capacidad del modelo para identificar correctamente a los pacientes sin ERC.
- **Puntuación F1 (F1-score):** Media armónica de la precisión y la sensibilidad, útil para conjuntos de datos desequilibrados.
- **Área bajo la curva ROC (Receiver Operating Characteristic) - AUC-ROC:** Mide la capacidad de un modelo para distinguir entre clases positivas y negativas. Un valor más cercano a 1 indica una mejor discriminación (Fawcett, 2006).
- **Curva de Precisión-Recall (PR-Curve):** Especialmente útil en casos de desequilibrio de clases, donde la AUC-ROC puede ser engañosa (Davis & Goadrich, 2006).

Se seleccionará el modelo con el mejor rendimiento en el conjunto de prueba, priorizando la sensibilidad y la especificidad sin comprometer excesivamente la precisión general, dada la implicación clínica de los falsos negativos en la predicción de la ERC.

4. Desarrollo de la Herramienta de Apoyo a la Decisión Clínica (HADC)

El modelo predictivo mejor evaluado se integrará en una HADC, diseñada para ser una interfaz intuitiva y práctica para profesionales de la salud. Las fases de desarrollo incluirán:

4.1. Diseño de la Arquitectura de la Herramienta

Se definirá la arquitectura de la HADC, considerando si será una aplicación web (recomendada)

4. Desarrollo de la Herramienta de Apoyo a la Decisión Clínica (HADC)

El modelo predictivo mejor evaluado se integrará en una HADC, diseñada para ser una interfaz intuitiva y práctica para profesionales de la salud. Las fases de desarrollo incluirán:

4.1. Diseño de la Arquitectura de la Herramienta

Se definirá la arquitectura de la HADC, considerando si será una aplicación web (recomendado por su accesibilidad y facilidad de despliegue), una aplicación de escritorio o una API para integrar en sistemas existentes. Se optará por una arquitectura que facilite la escalabilidad y el mantenimiento.

4.2. Desarrollo de la Interfaz de Usuario (UI)

Se diseñará una interfaz de usuario clara y amigable, centrada en la experiencia del usuario (UX) de los médicos. Los principios de diseño se enfocarán en la simplicidad, la eficiencia y la accesibilidad. La interfaz permitirá la entrada de los atributos clínicos del paciente y mostrará el riesgo predicho de ERC, junto con una justificación (si el modelo lo permite, utilizando técnicas de explicabilidad de ML como SHAP o LIME) y recomendaciones clínicas basadas en guías de práctica clínica relevantes (e.g., KDIGO).

4.3. Integración del Modelo Predictivo

El modelo de ML seleccionado se serializará y se integrará en el *backend* de la herramienta. Esto implicará la creación de una API que reciba los datos del paciente, los preprocese según las especificaciones del modelo y devuelva la predicción de riesgo.

4.4. Pruebas y Evaluación de Usabilidad

La HADC será sometida a pruebas rigurosas, incluyendo pruebas de funcionalidad, rendimiento y seguridad. Adicionalmente, se realizará una evaluación de usabilidad con un grupo de profesionales de la salud (médicos generales, nefrólogos, enfermeras) a través de cuestionarios y entrevistas semiestructuradas para obtener retroalimentación sobre la facilidad de uso, la utilidad clínica y la integración en su flujo de trabajo. Esta retroalimentación informará iteraciones de mejora de la herramienta (Zhang et al., 2011).

4.4. Pruebas y Evaluación de Usabilidad

La HADC será sometida a pruebas rigurosas, incluyendo pruebas de funcionalidad, rendimiento y seguridad. Adicionalmente, se realizará una evaluación de usabilidad con un grupo de profesionales de la salud (médicos generales, nefrólogos, enfermeras) a través de cuestionarios y entrevistas semiestructuradas para obtener retroalimentación sobre la facilidad de uso, la utilidad clínica y la integración en su flujo de trabajo. Esta retroalimentación informará iteraciones de mejora de la herramienta (Zhang et al., 2011).

5. Consideraciones Éticas y de Privacidad de Datos

Durante todo el proceso de investigación y desarrollo, se mantendrá un estricto apego a los principios éticos y de protección de datos. Se asegurará la anonimización de los datos del paciente. Se discutirán las implicaciones éticas del uso de modelos predictivos en la toma de decisiones clínicas, incluida la posible aparición de sesgos algorítmicos y la necesidad de transparencia en las predicciones (Chen et al., 2020). Se enfatizará que la herramienta es un apoyo a la decisión y no un sustituto del juicio clínico profesional.

6. Herramientas y Software

Para la implementación de esta metodología, se utilizarán las siguientes herramientas y software:

- **Lenguajes de Programación:** Python (para análisis de datos, desarrollo de modelos de ML y backend de la herramienta), JavaScript/HTML/CSS (para el frontend de la herramienta web).
- **Librerías de Python:** Pandas y NumPy para manipulación de datos; Scikit-learn para desarrollo de modelos de ML; Matplotlib y Seaborn para visualización de datos; Flask/Django (o FastAPI) para el desarrollo del backend de la aplicación web.
- **Entorno de Desarrollo Integrado (IDE):** Jupyter Notebooks para la exploración de datos y el prototipado del modelo; Visual Studio Code o PyCharm para el desarrollo de la aplicación.
- **Gestión de Bases de Datos:** SQLite (para prototipos) o PostgreSQL (para implementación más robusta) si la herramienta requiere persistencia de datos.

Citas encontradas por Gemini

- Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32.
- Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. En *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785-794). ACM.
- Chen, W., Zhang, Z., Ma, K., & Feng, D. (2020). Ethical Issues of Using Artificial Intelligence in Healthcare: A Systematic Review. *Journal of Medical Internet Research*, 22(12), e18200.
- Cortes, C., & Vapnik, V. (1995). Support-Vector Networks. *Machine Learning*, 20(3), 273-297.

6.9. Anexo 9: Resultado Claude tercer tema

R

Eres un analista de datos que tiene experiencia en análisis de datos y en investigaciones académicas. Tienes un fuerte background de medicina. Tienes una base de datos sobre la enfermedad renal crónica, estos datos tienen un número de atributos y una clasificación. Según estos datos, quieres hacer una investigación para una tesis de maestría, que tiene dos fines, uno utilizar un modelo para predecir la enfermedad, y otro hacer una herramienta para que los doctores lo utilicen de manera que ellos puedan predecir enfermedad renal crónica. Tu objetivo es plantear una selección de la metodología, intenta plantearla de forma que sea lo que se va a presentar en el documento final Asegúrate que solo sea el objetivo que te plantee. Por favor, quiero que hagas uso del internet, y me ayudes citando cualquier dato que necesites, necesito que estén citadas en apa. Dame también después de que termines las citas en bibtex. Asegurate que las citas en bibtex solo esten al final

METODOLOGÍA PARA PREDICCIÓN DE ENFERMEDAD RENAL CRÓNICA

1. Diseño de la Investigación

Esta investigación adopta un enfoque mixto cuantitativo-cualitativo con diseño transversal analítico (Hernández-Sampieri et al., 2018). El componente cuantitativo se centra en el desarrollo y validación de modelos predictivos para la enfermedad renal crónica (ERC), mientras que el cualitativo evalúa la usabilidad e integración clínica de la herramienta desarrollada.

2. Conjunto de Datos

Se utilizará un conjunto de datos de pacientes con diversos atributos clínicos y demográficos, incluyendo biomarcadores renales, comorbilidades y variables sociodemográficas. Los datos serán anonimizados siguiendo los principios éticos de investigación biomédica (Emanuel et al., 2020). La estructura y características del conjunto de datos se describirán mediante estadística descriptiva, identificando distribuciones de variables, valores atípicos y datos faltantes (Kuhn & Johnson, 2019).

3. Preprocesamiento de Datos

El preprocesamiento incluirá:

- Limpieza de datos: detección y manejo de valores atípicos y datos faltantes mediante técnicas como imputación múltiple (Buuren & Groothuis-Oudshoorn, 2011).

3. Preprocesamiento de Datos

El preprocesamiento incluirá:

- Limpieza de datos: detección y manejo de valores atípicos y datos faltantes mediante técnicas como imputación múltiple (Buuren & Groothuis-Oudshoorn, 2011).
- Normalización y estandarización de variables continuas para equilibrar su influencia en los modelos (Géron, 2019).
- Codificación de variables categóricas mediante one-hot encoding o encoding ordinal según su naturaleza (Brownlee, 2020).
- Análisis de correlación para identificar multicolinealidad y posible reducción de dimensionalidad (Hastie et al., 2009).

4. Selección de Características

Se implementarán métodos de selección de características para identificar los predictores más relevantes:

- Análisis univariante mediante pruebas estadísticas como chi-cuadrado para variables categóricas y prueba t o ANOVA para variables continuas (Guyon & Elisseeff, 2003).
- Métodos basados en modelo como Lasso (Least Absolute Shrinkage and Selection Operator) y Random Forest para importancia de variables (Tibshirani, 1996; Breiman, 2001).
- Métodos de wrapper con validación cruzada para evaluar subconjuntos de características (Kohavi & John, 1997).

5. División del Conjunto de Datos

Los datos se dividirán en tres subconjuntos (Raschka & Mirjalili, 2019):

- Conjunto de entrenamiento (70%): para el desarrollo de los modelos.
- Conjunto de validación (15%): para ajuste de hiperparámetros.
- Conjunto de prueba (15%): para evaluación final del rendimiento.

Se utilizará muestreo estratificado para mantener la distribución de la variable objetivo en cada subconjunto.

6. Modelos de Aprendizaje Automático

Se desarrollarán y evaluarán varios algoritmos de clasificación:

6. Modelos de Aprendizaje Automático

Se desarrollarán y evaluarán varios algoritmos de clasificación:

- Regresión Logística: como modelo de referencia por su interpretabilidad y uso común en medicina (Hosmer et al., 2013).
- Árboles de Decisión: por su capacidad de capturar relaciones no lineales y alta interpretabilidad (Quinlan, 1986).
- Random Forest: para mejorar la precisión mediante el ensamblado de múltiples árboles (Breiman, 2001).
- XGBoost: por su rendimiento superior en problemas de clasificación binaria (Chen & Guestrin, 2016).
- Redes Neuronales: específicamente una arquitectura de red feedforward multicapa para capturar relaciones complejas (Goodfellow et al., 2016).
- Máquinas de Vectores de Soporte: para problemas de clasificación de alta dimensionalidad (Cortes & Vapnik, 1995).

7. Optimización de Hiperparámetros

Para cada modelo se realizará una búsqueda exhaustiva de hiperparámetros:

- Grid Search con validación cruzada de 5 pliegues para explorar sistemáticamente el espacio de hiperparámetros (Bergstra & Bengio, 2012).
- Bayesian Optimization para modelos más complejos como XGBoost y redes neuronales (Snoek et al., 2012).

8. Evaluación de Modelos

Los modelos serán evaluados utilizando múltiples métricas:

- Precisión, sensibilidad, especificidad y F1-score para evaluar rendimiento general (Powers, 2011).
- Área bajo la curva ROC (AUC-ROC) para evaluar la capacidad discriminativa (Fawcett, 2006).
- Área bajo la curva Precision-Recall (PR-AUC) para conjuntos de datos con clases desbalanceadas (Davis & Goadrich, 2006).

9. Interpretabilidad del Modelo

Para garantizar la utilidad clínica, se aplicarán técnicas de interpretabilidad:

- Análisis de coeficientes para la regresión logística (Molnar, 2020).
- Importancia de características para Random Forest y XGBoost (Lundberg & Lee, 2017).
- SHAP (SHapley Additive exPlanations) para explicaciones locales y globales del modelo (Lundberg & Lee, 2017).
- LIME (Local Interpretable Model-agnostic Explanations) para explicaciones caso por caso (Ribeiro et al., 2016).
- Gráficos de dependencia parcial para visualizar relaciones entre predictores y resultados (Friedman, 2001).

10. Validación Externa

Para evaluar la generalizabilidad, se realizará validación externa (cuando sea posible):

- Validación temporal con datos más recientes para evaluar la estabilidad del modelo a lo largo del tiempo (Steyerberg & Harrell, 2016).
- Validación geográfica con datos de diferentes centros médicos para evaluar la transportabilidad (Collins et al., 2015).

11. Desarrollo de la Herramienta Clínica

La herramienta de predicción se desarrollará siguiendo estos pasos:

- Selección del modelo con mejor equilibrio entre rendimiento, interpretabilidad y robustez (Sendak et al., 2020).
- Desarrollo de una interfaz de usuario intuitiva siguiendo principios de diseño centrado en el usuario (Johnson et al., 2005).
- Integración de explicaciones interpretables para cada predicción (Caruana et al., 2015).
- Implementación de módulos de entrada de datos con validación y alertas de valores atípicos (Sutton et al., 2020).

12. Evaluación de la Herramienta

La herramienta será evaluada desde perspectivas técnicas y clínicas:

- Pruebas de usabilidad con profesionales de la salud utilizando métricas estándar como System Usability Scale (SUS) (Brooke, 1996).

13. Consideraciones Éticas

La investigación se adhiere a principios éticos estrictos:

- Aprobación por comité de ética de investigación antes de iniciar el estudio (Brakewood & Poldrack, 2013).
- Protección de datos y privacidad conforme a regulaciones locales e internacionales (Cohen & Mello, 2018).
- Evaluación de sesgos potenciales en los modelos y su impacto en diferentes subpoblaciones (Obermeyer et al., 2019).
- Transparencia en el desarrollo, limitaciones y uso previsto de la herramienta (Char et al., 2018).

14. Análisis Estadístico

Para todas las evaluaciones se emplearán técnicas estadísticas apropiadas:

- Pruebas de hipótesis con nivel de significancia de $\alpha=0.05$ y corrección para comparaciones múltiples cuando corresponda (Benjamini & Hochberg, 1995).
- Intervalos de confianza del 95% para todas las estimaciones de rendimiento (Gardner & Altman, 1986).
- Análisis de sensibilidad para evaluar la robustez de los resultados (Saltelli et al., 2008).

15. Cronograma y Gestión del Proyecto

El proyecto se estructurará en fases claramente definidas:

- Fase 1: Preparación de datos y análisis exploratorio (2 meses)
- Fase 2: Modelado y optimización (3 meses)
- Fase 3: Desarrollo de la herramienta (2 meses)
- Fase 4: Evaluación y refinamiento (2 meses)
- Fase 5: Documentación y difusión (1 mes)

Se utilizarán metodologías ágiles para la gestión del proyecto con revisiones periódicas y ajustes según sea necesario (Dingsøyr et al., 2012).

Referencias

- AETSA. (s.f.). Herramienta de ayuda a la toma de decisiones de pacientes susceptibles de diálisis. Descargado de https://www.aetsa.org/download/publicaciones/antiguas/AETSA_2009-8_HATD_ERC.pdf (Consultado el 10 de mayo de 2025)
- ahmetbersoz. (s.f.). *GitHub - ahmetbersoz/chatgpt-prompts-for-academic-writing: This list of writing prompts covers a range of topics and tasks, including brainstorming research ideas, improving language and style, conducting literature reviews, and developing research plans.* — *github.com*. <https://github.com/ahmetbersoz/chatgpt-prompts-for-academic-writing>. (Consultado el 10 de mayo de 2025)
- Alba, A. C., Agoritsas, T., Walsh, M., Hanna, S., Iorio, A., Devereaux, P. J., . . . Guyatt, G. (2017). Discrimination and calibration of clinical prediction models: users' guides to the medical literature. *Jama*, 318(14), 1377–1384.
- Bardo, B. (2025, marzo). *10 ChatGPT Prompts for Powerful Academic Writing* — *promptadvance.club*. <https://promptadvance.club/blog/chat-gpt-prompts-for-academic-writing>. (Consultado el 10 de mayo de 2025)
- Breiman, L. (2001a). Random forests. *Machine Learning*, 45(1), 5–32.
- Breiman, L. (2001b). Random forests. *Machine learning*, 45(1), 5–32.
- Brier, G. W. (1950). Verification of forecasts expressed in terms of probability. *Monthly weather review*, 78(1), 1–3.
- Brooke, J. (1996). Sus-a quick and dirty usability scale. *Usability evaluation in industry*, 189(194), 4–7.
- Buuren, S., y Groothuis-Oudshoorn, K. (2011). mice: Multivariate imputation by chained equations in r. *Journal of statistical software*, 45(3), 1–67.
- Caruana, R., Lou, Y., Gehrke, J., Koch, P., Sturm, M., y Elhadad, N. (2015). Intelligible models for healthcare: Predicting pneumonia risk and hospital 30-day readmission. *Proceedings of the 21th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 1721–1730.
- Char, D. S., Shah, N. H., y Magnus, D. (2018). Implementing machine learning in health care—addressing ethical challenges. *The New England journal of medicine*, 378(11), 981.
- Chen, T., y Guestrin, C. (2016). XGBoost: A scalable tree boosting system. En *Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining* (pp. 785–794). ACM.
- Cohen, I. G., y Mello, M. M. (2018). Hipaa and protecting health information in the 21st century. *Jama*, 320(3), 231–232.
- Cortes, C., y Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20(3), 273–297.
- Davis, J., y Goadrich, M. (2006). The relationship between precision-recall and roc curves. En *Proceedings of the 23rd international conference on machine learning* (pp. 233–240).
- Fawcett, T. (2006). An introduction to ROC analysis. *Pattern Recognition Letters*, 27(8), 861–874.
- García, C., y Romero, J. (2018). *Preprocesamiento de datos para machine learning*. Editorial Universitaria.
- Gonzalez, E. (2022). *Inteligencia artificial en la predicción de mortalidad por enfermedad renal crónica* (Vol. 12) (n.º 3). (Consultado el 10 de mayo de 2025)
- Goodfellow, I., Bengio, Y., y Courville, A. (2016). *Deep learning*. MIT Press.
- Greenhalgh, T., Wherton, J., Papoutsi, C., Lynch, J., Hughes, G., A'Court, C., . . . Shaw, S. (2017). Beyond adoption: a new framework for theorizing and evaluating nonadoption, abandonment, and challenges to the scale-up, spread, and sustainability of health and care technologies. *Journal of medical Internet research*, 19(11), e367.
- Guyon, I., y Elisseeff, A. (2003). An introduction to variable and feature selection. *Journal of machine learning research*, 3(Mar), 1157–1182.
- Géron, A. (2019). *Hands-on machine learning with scikit-learn, keras, and tensorflow: Concepts, tools, and techniques to build intelligent systems*. O'Reilly Media, Inc.
- Hastie, T., Tibshirani, R., y Friedman, J. (2009). *The elements of statistical learning: data mining, inference, and prediction*. Springer Science & Business Media.
- Hosmer, D. W., Lemeshow, S., y Sturdivant, R. X. (2013). *Applied logistic regression* (3.ª ed.). John Wiley & Sons.
- Hosmer Jr, D. W., Lemeshow, S., y Sturdivant, R. X. (2013). *Applied logistic regression*. John Wiley & Sons.
- James, G., Witten, D., Hastie, T., y Tibshirani, R. (2013). *An introduction to statistical learning with applications in r*. Springer.

- Johnson, J. (2005). Designing with the mind in mind: Simple guide to understanding user interface design guidelines. *Morgan Kaufmann*.
- Kohavi, R., y John, G. H. (1997). Wrappers for feature subset selection. *Artificial intelligence*, 97(1-2), 273–324.
- Kuhn, M., y Johnson, K. (2013). *Applied predictive modeling*. Springer.
- Matheny, M., Thadaney Israni, S., Ahmed, M., y Whicher, D. (2020). Artificial intelligence in health care: The hope, the hype, the promise, the peril. *NAM Special Publication*. Washington, DC: *National Academy of Medicine*, 154.
- Ministerio de Salud de Chile. (2010). *Guía clínica 2010 prevención enfermedad renal crónica*. Subsecretaría de Salud Pública. Descargado de https://www.superdesalud.gob.cl/difusion/572/articles-6453_recurso_1.pdf (Consultado el 10 de mayo de 2025)
- Obermeyer, Z., Powers, B., Vogeli, C., y Mullainathan, S. (2019). Dissecting racial bias in an algorithm used to manage the health of populations. *Science*, 366(6464), 447–453.
- Okorie, I. J. (2025). *My best ChatGPT prompts for academic writing — techpoint.africa*. <https://techpoint.africa/guide/best-chatgpt-prompts-for-academic-writing/>. (Consultado el 10 de mayo de 2025)
- Pillajo Sánchez, B. L., Guacho Guacho, J. S., y Moya Guerrero, I. R. (2021). La enfermedad renal crónica. revisión de la literatura y experiencia local en una ciudad de ecuador. *Revista de Ciencias de la Salud*, 5(1), 396–409.
- Powers, D. M. (2011). Evaluation: from precision, recall and f-measure to roc, informedness, markedness and correlation. *Journal of Machine Learning Technologies*, 2(1), 37–63.
- Quinlan, J. R. (1986). Induction of decision trees. *Machine learning*, 1(1), 81–106.
- Sendak, M. P., Gao, M., Brajer, N., y Balu, S. (2020). A path for translation of machine learning products into healthcare delivery. *EMJ Innov*, 5, 1–5.
- Sutton, R. T., Pincock, D., Baumgart, D. C., Sadowski, D. C., Fedorak, R. N., y Kroeker, K. I. (2020). An overview of clinical decision support systems: benefits, risks, and strategies for success. *NPJ Digital Medicine*, 3(1), 1–10.
- SysmexEspaña. (s.f.). *La importancia de la detección precoz de la enfermedad renal crónica*. Sysmex España. Descargado de <https://www.sysmex.es/academia/centro-de-conocimiento/sysmex-blog/urinalisis/dia-mundial-del-rinon-2022/> (Consultado el 10 de mayo de 2025)
- Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society: Series B (Methodological)*, 58(1), 267–288.
- Zhang, J., Johnson, T. R., Turley, J. P., Hogan, J., Palmer, R. M., y Gabriel, A. (2011). The role of usability in clinical decision support. *AMIA Joint Summits on Translational Science, 2011*, 142–146.